

Exercice 17

Relevons les données de l'énoncé, en distinguant bien les probabilités simples des probabilités conditionnelles :

$p(I) = 0,01$ (un fichier sur cent est infecté), donc $p(\bar{I}) = 1 - 0,01 = 0,99$;


$p(S/I) = 0,95$ (l'antivirus détecte 95 % des fichiers infectés) ;

$p(S/\bar{I}) = 0,02$ (il crie « au loup » sur 2 % des fichiers sains : les *faux positifs*).

$\{I; \bar{I}\}$ est un **système complet d'événements**.

1) a) Construire un arbre pondéré traduisant la situation.

Traçons l'arbre : premier niveau l'état réel du fichier, second niveau le verdict de l'antivirus.



Exercice 17 : arbre pondéré infecté/sain $\rightarrow$ suspect ou non.

Contrôlons : la somme des probabilités issues d'un même nœud vaut 1 ($0,01 + 0,99 = 1$, $0,95 + 0,05 = 1$, $0,02 + 0,98 = 1$) ✓

1) b) Calculer $p(S)$.

Méthode : la formule des probabilités totales sur $\{I; \bar{I}\}$: $p(S) = p(I)p(S/I) + p(\bar{I})p(S/\bar{I})$ — on additionne les deux chemins de l'arbre qui aboutissent à S .

Calculons les deux chemins menant à S :

$$p(I \cap S) = p(I)p(S/I) = 0,01 \times 0,95 = 0,0095$$

$$p(\bar{I} \cap S) = p(\bar{I})p(S/\bar{I}) = 0,99 \times 0,02 = 0,0198$$

Additionnons :

$$p(S) = 0,0095 + 0,0198$$

$$p(S) = 0,0293$$

$\Rightarrow$ environ 2,93 % des fichiers sont déclarés suspects par l'antivirus

2) a) Un fichier est déclaré suspect. Calculer $p(I/S)$ (arrondir à 10^{-4}).

Méthode : la formule de Bayes : $p(I/S) = \frac{p(I \cap S)}{p(S)}$. On remonte l'arbre — attention à ne pas confondre $p(I/S)$ avec $p(S/I) = 0,95$, qui se lit dans l'autre sens.

Appliquons-la, licite car $p(S) = 0,0293 \neq 0$:

$$p(I/S) = \frac{p(I \cap S)}{p(S)} = \frac{0,0095}{0,0293}$$

Simplifions en multipliant haut et bas par 10 000 :

$$p(I/S) = \frac{95}{293} \approx 0,32423$$

$$p(I/S) = \frac{95}{293} \approx 0,3242$$

2) b) Commenter ce résultat.

Observons le contraste : l'antivirus détecte 95 % des fichiers infectés, et pourtant un fichier signalé « suspect » n'a qu'environ 32,4 % de chances d'être réellement infecté.

Expliquons-le en comparant les deux chemins menant à S :

les vrais positifs pèsent 0,009 5, les faux positifs 0,019 8 — soit *deux fois plus*.

La cause est le très faible taux de base : les fichiers sains sont 99 fois plus nombreux que les infectés, donc même un petit taux d'erreur (2 %) sur cette immense majorité produit beaucoup d'alertes.

⇒ **une alerte de l'antivirus ne doit pas être prise pour une certitude : environ deux fichiers signalés sur trois sont en réalité sains**

3) a) On analyse 20 fichiers sains de façon indépendante. Soit X le nombre de « faux positifs ». Déterminer la loi de X .

Vérifions les conditions du schéma de Bernoulli :

- chaque analyse a deux issues : le fichier sain est déclaré suspect (le « succès », ici un faux positif) ou non ;

- les épreuves sont identiques, de probabilité de succès $p = p(S/\bar{I}) = 0,02$;

- elles sont indépendantes, comme le précise l'énoncé.

X compte les succès parmi ces 20 épreuves.

⇒ X suit la loi binomiale $\mathcal{B}(20 ; 0,02)$

3) b) Calculer $E(X)$.

Appliquons la formule $E(X) = np$:

$$E(X) = 20 \times 0,02$$

$$E(X) = 0,4$$

⇒ **sur 20 fichiers sains, l'antivirus déclenche en moyenne 0,4 fausse alerte**

3) c) Calculer $p(X \geq 1)$ (arrondir à 10^{-3}).

Passons au contraire : le contraire de « au moins un faux positif » est « aucun faux positif », c'est-à-dire ($X = 0$).

$$p(X = 0) = C_{20}^0 (0,02)^0 (0,98)^{20} = (0,98)^{20} \approx 0,667 61$$

Retranchons de 1 :

$$p(X \geq 1) = 1 - p(X = 0) \approx 1 - 0,667 61 = 0,332 39$$

$$p(X \geq 1) = 1 - (0,98)^{20} \approx 0,332$$

⇒ **il y a environ une chance sur trois qu'au moins un des 20 fichiers sains soit signalé à tort**

4) Combien de fichiers sains peut-on analyser, au maximum, pour que la probabilité d'observer au moins un faux positif reste inférieure à 0,5 ?

Généralisons la question précédente à n fichiers sains :

$$p(\text{au moins un faux positif}) = 1 - (0,98)^n$$

Traduisons la contrainte :

$$1 - (0,98)^n < 0,5, \text{ soit } (0,98)^n > 0,5$$

Méthode : on compose par $\ln$ pour descendre n de l'exposant ; la division finale par $\ln(0,98)$, qui est négatif, change le sens de l'inégalité.

Composons par $\ln$, strictement croissante :

$$n \ln(0,98) > \ln(0,5)$$

Divisons par $\ln(0,98) \approx -0,020\,2 < 0$:

$$n < \frac{\ln(0,5)}{\ln(0,98)} \approx \frac{-0,693\,1}{-0,020\,2} \approx 34,31$$

Concluons : n est entier et $n < 34,31$, donc $n \leq 34$.

$$n_{\max} = 34$$

Vérifions de part et d'autre :

pour $n = 34$: $(0,98)^{34} \approx 0,503\,1 > 0,5$ ✓

pour $n = 35$: $(0,98)^{35} \approx 0,493\,1 < 0,5$ ✕

⇒ **au-delà de 34 fichiers sains analysés, il devient plus probable qu'improbable de rencontrer au moins une fausse alerte**