

Statistiques

Corrigés détaillés

Corrigé — Exercice 1

1) a) Calculer $\bar{x}$ et $\bar{y}$.

Calculons les deux moyennes sur les $n = 5$ jours observés :

$$\bar{x} = \frac{2 + 4 + 6 + 8 + 10}{5} = \frac{30}{5} = 6$$

$$\bar{y} = \frac{3 + 4 + 7 + 6 + 10}{5} = \frac{30}{5} = 6$$

$\Rightarrow \bar{x} = 6$ heures et $\bar{y} = 6$ milliers de requêtes

1) b) Donner les coordonnées du point moyen G .

Le point moyen du nuage a pour coordonnées $(\bar{x}; \bar{y})$.

$\Rightarrow G(6; 6)$

2) a) Calculer $\text{Cov}(X, Y)$.

Calculons d'abord la moyenne des produits $\overline{xy}$.

Les produits $x_i y_i$ valent : $2 \times 3 = 6$; $4 \times 4 = 16$; $6 \times 7 = 42$; $8 \times 6 = 48$; $10 \times 10 = 100$.

$$\overline{xy} = \frac{6 + 16 + 42 + 48 + 100}{5} = \frac{212}{5} = 42,4$$

Appliquons la formule $\text{Cov}(X, Y) = \overline{xy} - \bar{x} \bar{y}$:

$$\text{Cov}(X, Y) = 42,4 - 6 \times 6 = 42,4 - 36$$

$$\text{Cov}(X, Y) = 6,4$$

2) b) Préciser si X et Y varient dans le même sens.

Le signe de la covariance donne le sens de variation commun des deux caractères.

Ici $\text{Cov}(X, Y) = 6,4 > 0$.

$\Rightarrow X$ et Y varient dans le même sens : plus le serveur fonctionne longtemps, plus il traite de requêtes

3) Déterminer une équation de la droite de régression de y en x .

Méthode : la droite des moindres carrés de y en x s'écrit $y = ax + b$ avec $a = \frac{\text{Cov}(X, Y)}{V(X)}$ puis $b = \bar{y} - a \bar{x}$.

Calculons $V(X)$ par la formule $\overline{x^2} - \bar{x}^2$:

$$\overline{x^2} = \frac{4 + 16 + 36 + 64 + 100}{5} = \frac{220}{5} = 44$$

$$V(X) = 44 - 6^2 = 44 - 36 = 8$$

Déterminons la pente a :

$$a = \frac{\text{Cov}(X, Y)}{V(X)} = \frac{6,4}{8} = 0,8$$

Déterminons l'ordonnée à l'origine b :

$$b = \bar{y} - a \bar{x} = 6 - 0,8 \times 6 = 6 - 4,8 = 1,2$$

$$y = 0,8x + 1,2$$

4) a) Calculer le coefficient de corrélation r (arrondi à 10^{-2}).

Calculons $V(Y)$ de la même façon :

$$\overline{y^2} = \frac{9 + 16 + 49 + 36 + 100}{5} = \frac{210}{5} = 42$$

$$V(Y) = 42 - 6^2 = 42 - 36 = 6$$

$$\text{Appliquons } r = \frac{\text{Cov}(X, Y)}{\sigma(X) \sigma(Y)} = \frac{\text{Cov}(X, Y)}{\sqrt{V(X) \times V(Y)}} :$$

$$r = \frac{6,4}{\sqrt{8 \times 6}} = \frac{6,4}{\sqrt{48}}$$

$$\sqrt{48} \approx 6,928, \text{ donc } r \approx \frac{6,4}{6,928} \approx 0,9238.$$

$$r \approx 0,92$$

4) b) L'ajustement affine est-il justifié?

Comparons $|r|$ au seuil $\frac{\sqrt{3}}{2} \approx 0,87$:

$$|r| \approx 0,92 > 0,87$$

$\Rightarrow$ **oui** : $|r| > \frac{\sqrt{3}}{2}$, la corrélation linéaire est forte et l'ajustement affine est justifié

5) a) Estimer y pour $x = 12$ heures d'utilisation.

Remplaçons x par 12 dans la droite de régression de y en x :

$$y = 0,8 \times 12 + 1,2 = 9,6 + 1,2 = 10,8$$

$\Rightarrow$ **environ 10,8 milliers de requêtes, soit à peu près 10 800 requêtes**

5) b) Cette estimation appelle-t-elle une réserve?

Les durées relevées vont de 2 à 10 heures.

La valeur $x = 12$ est *en dehors* de cette plage : on fait une extrapolation.

$\Rightarrow$ **oui** : rien ne garantit que la liaison reste affine au-delà de 10 heures, l'estimation doit être prise avec prudence

6) Vérifier que le point moyen G appartient à la droite de régression.

Remplaçons x par $\bar{x} = 6$ dans l'équation $y = 0,8x + 1,2$:

$$0,8 \times 6 + 1,2 = 4,8 + 1,2 = 6 = \bar{y} \quad \checkmark$$

$\Rightarrow G(6; 6)$ **appartient bien à la droite** : c'est une propriété générale de la droite des moindres carrés

7) Calculer $V(X)$ et l'écart-type $\sigma(X)$.

La variance a déjà été obtenue à la question 3) :

$$V(X) = \overline{x^2} - \bar{x}^2 = 44 - 36 = 8$$

Prenons la racine carrée pour obtenir l'écart-type :

$$\sigma(X) = \sqrt{8} = 2\sqrt{2} \approx 2,83$$

$$V(X) = 8 ; \quad \sigma(X) = 2\sqrt{2} \approx 2,83$$

Corrigé — Exercice 2

1) Déterminer la distribution marginale de X (compléter la colonne « Total »).

Méthode : la distribution marginale de X s'obtient en sommant chaque ligne du tableau à double entrée.

Sommons les effectifs ligne par ligne :

$$\text{ligne } x = 5 : 2 + 3 + 4 + 1 = 10$$

$$\text{ligne } x = 10 : 3 + 5 + 8 + 4 = 20$$

$$\text{ligne } x = 15 : 4 + 6 + 7 + 3 = 20$$

$$\text{Vérifions l'effectif total : } 10 + 20 + 20 = 50 \quad \checkmark$$

$\Rightarrow$ la distribution marginale de X est : $(5; 10), (10; 20), (15; 20)$, d'effectif total $N = 50$

2) Calculer $\bar{x}$, $V(X)$ et $\sigma(X)$.

Calculons la moyenne à partir de la distribution marginale :

$$\bar{x} = \frac{5 \times 10 + 10 \times 20 + 15 \times 20}{50} = \frac{50 + 200 + 300}{50} = \frac{550}{50}$$

$$\bar{x} = 11$$

Calculons la moyenne des carrés :

$$\overline{x^2} = \frac{25 \times 10 + 100 \times 20 + 225 \times 20}{50} = \frac{250 + 2000 + 4500}{50} = \frac{6750}{50} = 135$$

$$\text{Appliquons } V(X) = \overline{x^2} - \bar{x}^2 :$$

$$V(X) = 135 - 11^2 = 135 - 121 = 14$$

$$\text{Prenons la racine carrée : } \sigma(X) = \sqrt{14} \approx 3,74.$$

$$\bar{x} = 11 ; \quad V(X) = 14 ; \quad \sigma(X) = \sqrt{14} \approx 3,74$$

3) Déterminer la distribution marginale de Y .

Méthode : la distribution marginale de Y s'obtient cette fois en sommant chaque colonne.

Sommons les effectifs colonne par colonne :

$$\text{colonne } y = 0 : 2 + 3 + 4 = 9$$

$$\text{colonne } y = 1 : 3 + 5 + 6 = 14$$

$$\text{colonne } y = 2 : 4 + 8 + 7 = 19$$

$$\text{colonne } y = 3 : 1 + 4 + 3 = 8$$

$$\text{Vérifions l'effectif total : } 9 + 14 + 19 + 8 = 50 \quad \checkmark$$

$\Rightarrow$ la distribution marginale de Y est : $(0; 9), (1; 14), (2; 19), (3; 8)$

4) Calculer $\bar{y}$ et $\sigma(Y)$ (arrondir à 10^{-2}).

Calculons la moyenne de Y :

$$\bar{y} = \frac{0 \times 9 + 1 \times 14 + 2 \times 19 + 3 \times 8}{50} = \frac{0 + 14 + 38 + 24}{50} = \frac{76}{50}$$

$$\bar{y} = 1,52$$

Calculons la moyenne des carrés :

$$\overline{y^2} = \frac{0 \times 9 + 1 \times 14 + 4 \times 19 + 9 \times 8}{50} = \frac{14 + 76 + 72}{50} = \frac{162}{50} = 3,24$$

$$\text{Appliquons } V(Y) = \overline{y^2} - \bar{y}^2 :$$

$$V(Y) = 3,24 - 1,52^2 = 3,24 - 2,3104 = 0,9296$$

$$\sigma(Y) = \sqrt{0,9296} \approx 0,9642$$

$$\bar{y} = 1,52 ; \quad \sigma(Y) \approx 0,96$$

5) Parmi les clients payant 10 dinars, quelle est la fréquence de ceux ayant souscrit au moins 2 services ?

Méthode : on travaille dans la ligne $X = 10$ seule : c'est une fréquence conditionnelle, l'effectif de référence est celui de la ligne.

Lisons la ligne $X = 10$: les effectifs sont 3, 5, 8, 4, soit 20 clients au total.

« Au moins 2 services » signifie $Y = 2$ ou $Y = 3$:

$$8 + 4 = 12 \text{ clients}$$

Calculons la fréquence : $\frac{12}{20} = 0,6$.

$\Rightarrow$ 60 % des clients payant 10 dinars ont souscrit au moins 2 services

Corrigé — Exercice 3

1) Calculer $\bar{x}$ et $\bar{y}$.

Calculons les deux moyennes sur les $n = 5$ couples :

$$\bar{x} = \frac{1 + 2 + 3 + 4 + 5}{5} = \frac{15}{5} = 3$$

$$\bar{y} = \frac{3 + 5 + 7 + 7 + 13}{5} = \frac{35}{5} = 7$$

$$\Rightarrow \bar{x} = 3 \text{ et } \bar{y} = 7$$

2) Calculer $\text{Cov}(X, Y)$.

Calculons d'abord la moyenne des produits.

Les produits $x_i y_i$ valent : $1 \times 3 = 3$; $2 \times 5 = 10$; $3 \times 7 = 21$; $4 \times 7 = 28$; $5 \times 13 = 65$.

$$\overline{xy} = \frac{3 + 10 + 21 + 28 + 65}{5} = \frac{127}{5} = 25,4$$

Appliquons $\text{Cov}(X, Y) = \overline{xy} - \bar{x} \bar{y}$:

$$\text{Cov}(X, Y) = 25,4 - 3 \times 7 = 25,4 - 21$$

$$\text{Cov}(X, Y) = 4,4$$

3) Déterminer une équation de la droite de régression de y en x .

Méthode : droite des moindres carrés de y en x : $y = ax + b$ avec $a = \frac{\text{Cov}(X, Y)}{V(X)}$ puis $b = \bar{y} - a \bar{x}$.

Calculons $V(X)$:

$$\overline{x^2} = \frac{1 + 4 + 9 + 16 + 25}{5} = \frac{55}{5} = 11$$

$$V(X) = 11 - 3^2 = 11 - 9 = 2$$

Déterminons la pente :

$$a = \frac{4,4}{2} = 2,2$$

Déterminons l'ordonnée à l'origine :

$$b = \bar{y} - a \bar{x} = 7 - 2,2 \times 3 = 7 - 6,6 = 0,4$$

$$y = 2,2x + 0,4$$

Vérifions que le point moyen $G(3; 7)$ est bien sur la droite :

$$2,2 \times 3 + 0,4 = 6,6 + 0,4 = 7 = \bar{y} \quad \checkmark$$

4) Calculer r (arrondi à 10^{-2}) ; commenter.

Calculons $V(Y)$:

$$\overline{y^2} = \frac{9 + 25 + 49 + 49 + 169}{5} = \frac{301}{5} = 60,2$$

$$V(Y) = 60,2 - 7^2 = 60,2 - 49 = 11,2$$

Appliquons $r = \frac{\text{Cov}(X, Y)}{\sqrt{V(X) \times V(Y)}}$:

$$r = \frac{4,4}{\sqrt{2 \times 11,2}} = \frac{4,4}{\sqrt{22,4}}$$

$$\sqrt{22,4} \approx 4,733, \text{ donc } r \approx \frac{4,4}{4,733} \approx 0,9297.$$

$$r \approx 0,93$$

Comparons au seuil : $0,93 > \frac{\sqrt{3}}{2} \approx 0,87$.

⇒ la corrélation linéaire est forte et positive : l'ajustement affine est justifié

5) a) Estimer y pour $x = 7$.

Remplaçons x par 7 dans $y = 2,2x + 0,4$:

$$y = 2,2 \times 7 + 0,4 = 15,4 + 0,4 = 15,8$$

⇒ $y \approx 15,8$ (valeur extrapolée : 7 sort de la plage $[1 ; 5]$ des données)

5) b) Pour quelle valeur de x l'estimation atteint-elle $y = 20$?

Réolvons l'équation $2,2x + 0,4 = 20$:

$$2,2x = 20 - 0,4 = 19,6$$

$$x = \frac{19,6}{2,2} \approx 8,909$$

$$x \approx 8,9$$

Vérifions : $2,2 \times 8,909 + 0,4 \approx 20$. ✓

Corrigé — Exercice 4

1) Calculer $\sigma(X)$ et $\sigma(Y)$.

Calculons d'abord les deux moyennes :

$$\bar{x} = \frac{1+2+3+4+5}{5} = 3 \quad \text{et} \quad \bar{y} = \frac{2+4+5+4+10}{5} = \frac{25}{5} = 5$$

Calculons $V(X) = \overline{x^2} - \bar{x}^2$:

$$\overline{x^2} = \frac{1+4+9+16+25}{5} = \frac{55}{5} = 11 \quad \text{donc} \quad V(X) = 11 - 9 = 2$$

$$\sigma(X) = \sqrt{2} \approx 1,41$$

Calculons $V(Y) = \overline{y^2} - \bar{y}^2$:

$$\overline{y^2} = \frac{4+16+25+16+100}{5} = \frac{161}{5} = 32,2 \quad \text{donc} \quad V(Y) = 32,2 - 25 = 7,2$$

$$\sigma(Y) = \sqrt{7,2} \approx 2,683$$

$$\sigma(X) = \sqrt{2} \approx 1,41 ; \quad \sigma(Y) = \sqrt{7,2} \approx 2,68$$

2) Calculer le coefficient de corrélation r (arrondi à 10^{-2}).

Calculons la covariance.

Les produits $x_i y_i$ valent : $1 \times 2 = 2$; $2 \times 4 = 8$; $3 \times 5 = 15$; $4 \times 4 = 16$; $5 \times 10 = 50$.

$$\overline{xy} = \frac{2+8+15+16+50}{5} = \frac{91}{5} = 18,2$$

$$\text{Cov}(X, Y) = 18,2 - 3 \times 5 = 18,2 - 15 = 3,2$$

Appliquons $r = \frac{\text{Cov}(X, Y)}{\sigma(X) \sigma(Y)}$:

$$r = \frac{3,2}{\sqrt{2} \times \sqrt{7,2}} = \frac{3,2}{\sqrt{14,4}}$$

$$\sqrt{14,4} \approx 3,795, \text{ donc } r \approx \frac{3,2}{3,795} \approx 0,8433.$$

$$r \approx 0,84$$

3) Un ajustement affine est-il justifié selon le seuil $\sqrt{3}/2$? Et selon le seuil 0,75? Commenter.

Comparons $|r| \approx 0,84$ au premier seuil :

$$\frac{\sqrt{3}}{2} \approx 0,87 \text{ et } 0,84 < 0,87 : \text{ avec ce seuil, l'ajustement affine n'est pas justifié.}$$

Comparons maintenant au second seuil :

$$0,84 > 0,75 : \text{ avec ce seuil, l'ajustement affine est justifié.}$$

⇒ la conclusion dépend du seuil choisi ; la corrélation est ici seulement *modérée*

Commentaire : deux conventions coexistent selon les manuels. Au bac, il faut toujours utiliser le seuil *donné par l'énoncé*, et le citer explicitement dans la conclusion.

4) Déterminer une équation de la droite de régression de y en x .

Méthode : droite des moindres carrés de y en x : $y = ax + b$ avec $a = \frac{\text{Cov}(X, Y)}{V(X)}$ puis $b = \bar{y} - a\bar{x}$.

Déterminons la pente :

$$a = \frac{3,2}{2} = 1,6$$

Déterminons l'ordonnée à l'origine :

$$b = \bar{y} - a\bar{x} = 5 - 1,6 \times 3 = 5 - 4,8 = 0,2$$

$$y = 1,6x + 0,2$$

Vérifions que $G(3; 5)$ est sur la droite : $1,6 \times 3 + 0,2 = 5 = \bar{y}$. ✓

5) En admettant l'ajustement, estimer y pour $x = 6$; pourquoi cette estimation doit-elle être prise avec prudence ?

Remplaçons x par 6 dans $y = 1,6x + 0,2$:

$$y = 1,6 \times 6 + 0,2 = 9,6 + 0,2 = 9,8$$

$$\Rightarrow y \approx 9,8$$

Deux réserves s'imposent :

- la corrélation n'est que modérée ($r \approx 0,84$, sous le seuil $\sqrt{3}/2$) : la droite représente imparfaitement le nuage ;
- $x = 6$ est en dehors de la plage observée $[1; 5]$: c'est une extrapolation.

Corrigé — Exercice 5

1) Calculer le coefficient de corrélation r .

Calculons d'abord les deux écarts-types :

$$\sigma(X) = \sqrt{V(X)} = \sqrt{25} = 5 \quad \text{et} \quad \sigma(Y) = \sqrt{V(Y)} = \sqrt{16} = 4$$

Appliquons $r = \frac{\text{Cov}(X, Y)}{\sigma(X) \sigma(Y)}$:

$$r = \frac{18}{5 \times 4} = \frac{18}{20}$$

$$r = 0,9$$

2) Un ajustement affine est-il justifié ?

Comparons $|r|$ au seuil $\frac{\sqrt{3}}{2} \approx 0,87$:

$$0,9 > 0,87$$

$\Rightarrow$ oui : $|r| > \frac{\sqrt{3}}{2}$, l'ajustement affine est justifié

3) Donner la droite de régression de y en x , puis estimer y pour $x = 15$.

Méthode : droite des moindres carrés de y en x : $y = ax + b$ avec $a = \frac{\text{Cov}(X, Y)}{V(X)}$ puis $b = \bar{y} - a\bar{x}$.

Déterminons la pente :

$$a = \frac{18}{25} = 0,72$$

Déterminons l'ordonnée à l'origine :

$$b = \bar{y} - a\bar{x} = 6 - 0,72 \times 10 = 6 - 7,2 = -1,2$$

$$y = 0,72x - 1,2$$

Remplaçons x par 15 :

$$y = 0,72 \times 15 - 1,2 = 10,8 - 1,2 = 9,6$$

$\Rightarrow$ pour $x = 15$, l'estimation est $y = 9,6$

4) Déterminer une équation de la droite de régression de x en y .

Méthode : on échange les rôles : $x = a'y + b'$ avec $a' = \frac{\text{Cov}(X, Y)}{V(Y)}$ puis $b' = \bar{x} - a'\bar{y}$. C'est cette droite-là qui sert à estimer x connaissant y .

Déterminons la pente :

$$a' = \frac{18}{16} = 1,125$$

Déterminons l'ordonnée à l'origine :

$$b' = \bar{x} - a'\bar{y} = 10 - 1,125 \times 6 = 10 - 6,75 = 3,25$$

$$x = 1,125y + 3,25$$

5) Vérifier que le produit des deux pentes est égal à r^2 .

Calculons le produit des deux pentes obtenues :

$$a \times a' = 0,72 \times 1,125 = 0,81$$

Calculons r^2 : $r^2 = 0,9^2 = 0,81$. ✓

$$\Rightarrow a \times a' = r^2 = 0,81$$

Ce n'est pas un hasard, la propriété est générale :

$$a \times a' = \frac{\text{Cov}(X, Y)}{V(X)} \times \frac{\text{Cov}(X, Y)}{V(Y)} = \frac{(\text{Cov}(X, Y))^2}{V(X) V(Y)} = r^2$$

Les deux droites se confondent donc lorsque $r^2 = 1$, c'est-à-dire lorsque les points sont exactement alignés.

Corrigé — Exercice 6 — Bac principal 2016

1) a) Représenter le nuage de points $(x_i ; y_i)$ dans un repère orthogonal.

Plaçons les sept points $M_i(x_i ; y_i) : (1 ; 8,1), (2 ; 11,4), (3 ; 14,3), (4 ; 17,1), (5 ; 22), (6 ; 28,8)$ et $(7 ; 33,5)$.

Les unités sont choisies différentes sur les deux axes (1 rang en abscisse, 5 % en ordonnée) pour que le nuage occupe bien la figure.

⇒ voir le nuage tracé ci-dessous

1) b) Expliquer pourquoi un ajustement affine de ce nuage est justifié.

Méthode : « justifier un ajustement affine » se démontre par le calcul de r , pas seulement par l'allure du dessin.

Calculons d'abord les moyennes :

$$\bar{x} = \frac{1 + 2 + 3 + 4 + 5 + 6 + 7}{7} = \frac{28}{7} = 4$$

$$\bar{y} = \frac{8,1 + 11,4 + 14,3 + 17,1 + 22 + 28,8 + 33,5}{7} = \frac{135,2}{7} \approx 19,3143$$

Calculons la covariance :

$$\overline{xy} = \frac{8,1 + 22,8 + 42,9 + 68,4 + 110 + 172,8 + 234,5}{7} = \frac{659,5}{7} \approx 94,2143$$

$$\text{Cov}(X, Y) \approx 94,2143 - 4 \times 19,3143 \approx 16,96$$

Calculons les deux écarts-types :

$$\overline{x^2} = \frac{140}{7} = 20, \text{ donc } V(X) = 20 - 4^2 = 4 \text{ et } \sigma(X) = 2.$$

$$\overline{y^2} = \frac{3128,16}{7} = 446,88$$

$$V(Y) \approx 446,88 - 373,04 \approx 73,84 \text{ et } \sigma(Y) \approx 8,59.$$

Appliquons $r = \frac{\text{Cov}(X, Y)}{\sigma(X)\sigma(Y)}$:

$$r \approx \frac{16,96}{2 \times 8,59} \approx \frac{16,96}{17,19} \approx 0,99$$

Comparons au seuil : $0,99 > \frac{\sqrt{3}}{2} \approx 0,87$.

⇒ $|r|$ est très proche de 1 : les points sont presque alignés, l'ajustement affine est justifié

1) c) Calculer, à 0,1 près, les coordonnées du point moyen G . Placer G .

Le point moyen est $G(\bar{x} ; \bar{y})$; les deux moyennes ont été calculées en 1) b).

$$\bar{x} = 4 \quad \text{et} \quad \bar{y} = \frac{135,2}{7} \approx 19,3$$

$$G(4 ; 19,3)$$

Sur la figure, G est le point orange : il est bien au « centre » du nuage.

2) a) Par la méthode des moindres carrés, donner l'équation de la droite de régression de y en x .

Méthode : $y = ax + b$ avec $a = \frac{\text{Cov}(X, Y)}{V(X)}$ puis $b = \bar{y} - a\bar{x}$.

Déterminons la pente :

$$a = \frac{16,96}{4} \approx 4,24$$

Déterminons l'ordonnée à l'origine :

$$b = \bar{y} - a\bar{x} \approx 19,3143 - 4,2393 \times 4 \approx 2,36$$

$$y = 4,24x + 2,36$$

Attention : le calcul de b doit se faire avec $\bar{y}$ *non arrondi*. Avec $\bar{y} = 19,3$ on trouverait 2,34 : l'arrondi se propage et fausse le résultat final.

Vérifions que G appartient à la droite : $4,24 \times 4 + 2,36 = 19,32 \approx \bar{y}$. ✓

2) b) Estimer la proportion des ménages abonnés à Internet en 2018.

Déterminons le rang de l'année 2018.

L'année 2009 a le rang 1, donc 2018 a le rang $2018 - 2008 = 10$.

Remplaçons x par 10 dans la droite de régression :

$$y = 4,24 \times 10 + 2,36 = 42,4 + 2,36 = 44,76$$

En 2018, environ 44,8 % des ménages seraient abonnés à Internet.

3) Peut-on, à l'aide de cet ajustement, estimer cette proportion en 2032 ? Justifier.


Déterminons le rang de 2032 : $2032 - 2008 = 24$.

Calculons l'estimation correspondante :

$$y = 4,24 \times 24 + 2,36 = 101,76 + 2,36 = 104,12$$

Or y est un *pourcentage* de ménages : il ne peut pas dépasser 100 %.

⇒ **non** : l'extrapolation est beaucoup trop lointaine (24 contre 7 rangs observés) et donne un résultat impossible, l'ajustement affine n'est plus valable si loin des données



Corrigé Ex 6 : nuage, point moyen $G(4 ; 19,3)$ et droite $y = 4,24x + 2,36$.

Corrigé — Exercice 7 — Bac contrôle 2020

1) a) Représenter le nuage de la série statistique double (x, y) .

Plaçons les huit points $M_i(x_i; y_i)$: $(1; 73,7)$, $(2; 77,9)$, $(3; 86,8)$, $(4; 93,6)$, $(5; 85,3)$, $(6; 90)$, $(7; 110,4)$ et $(8; 125)$.

Toutes les ordonnées sont comprises entre 73 et 125 : on tronque l'axe des ordonnées à partir de 60, sinon le nuage se tasserait en haut de la figure.

Observons l'allure : la croissance est globalement régulière, mais le point de rang 5 (85,3) est *en dessous* du point de rang 4 (93,6). Ce « creux » est la seule irrégularité du nuage.

⇒ voir le nuage tracé ci-dessous

1) b) Peut-on envisager un ajustement affine de la série (x, y) ? Justifier (on calculera r).

Méthode : répondre à « peut-on envisager un ajustement affine ? » exige le calcul de r et sa comparaison à un seuil : l'allure du dessin ne suffit jamais comme justification.

Calculons les deux moyennes ($n = 8$) :

$$\bar{x} = \frac{1 + 2 + 3 + 4 + 5 + 6 + 7 + 8}{8} = \frac{36}{8} = 4,5$$

$$\bar{y} = \frac{73,7 + 77,9 + 86,8 + 93,6 + 85,3 + 90 + 110,4 + 125}{8} = \frac{742,7}{8} = 92,8375$$

Calculons la covariance à l'aide de $\text{Cov}(X, Y) = \overline{xy} - \bar{x}\bar{y}$.

Les produits $x_i y_i$ valent : 73,7; 155,8; 260,4; 374,4; 426,5; 540; 772,8; 1000.

$$\overline{xy} = \frac{3603,6}{8} = 450,45$$

$$\text{Cov}(X, Y) = 450,45 - 4,5 \times 92,8375 = 450,45 - 417,76875 = 32,68125$$

Calculons les deux variances avec $V = \overline{u^2} - \bar{u}^2$:

$$\overline{x^2} = \frac{204}{8} = 25,5$$

$$V(X) = 25,5 - 4,5^2 = 25,5 - 20,25 = 5,25 \text{ et } \sigma(X) \approx 2,2913.$$

$$\overline{y^2} = \frac{70\,984,55}{8} = 8873,06875$$

$$V(Y) = 8873,06875 - 92,8375^2 \approx 254,2673 \text{ et } \sigma(Y) \approx 15,9458.$$

$$\text{Appliquons } r = \frac{\text{Cov}(X, Y)}{\sigma(X)\sigma(Y)} :$$

$$r \approx \frac{32,68125}{2,2913 \times 15,9458} \approx \frac{32,68125}{36,5362} \approx 0,8945$$

$$r \approx 0,89$$

Comparons au seuil usuel : $\frac{\sqrt{3}}{2} \approx 0,87$ et $0,89 > 0,87$.

⇒ oui : $|r|$ dépasse le seuil, la corrélation reste forte malgré le creux du rang 5, un ajustement affine peut être envisagé

2) Les valeurs seront arrondies à 10^{-1} près. Donner une équation de la droite de régression de y en x .

Méthode : droite des moindres carrés de y en x : $y = ax + b$ avec $a = \frac{\text{Cov}(X, Y)}{V(X)}$, puis $b = \bar{y} - a\bar{x}$.

Déterminons la pente :

$$a = \frac{32,68125}{5,25} = 6,225 \approx 6,2$$


Déterminons l'ordonnée à l'origine, en gardant la valeur *non arrondie* de a :

$$b = 92,8375 - 6,225 \times 4,5 = 92,8375 - 28,0125 = 64,825 \approx 64,8$$

$$y = 6,2x + 64,8$$

Attention : si l'on reporte $a \approx 6,2$ au lieu de $6,225$, on obtient $b \approx 64,9$. L'arrondi ne doit intervenir qu'à la toute fin de chaque calcul.

Vérifions que le point moyen $G(4,5 ; 92,8)$ appartient à la droite : $6,225 \times 4,5 + 64,825 = 92,8375 = \bar{y}$. ✓



Corrigé Ex 7 : nuage du C.A. Microsoft et droite $y = 6,2x + 64,8$ (axe y tronqué).

Corrigé — Exercice 8 — Bac contrôle 2022

1) a) Déterminer le coefficient de corrélation r du couple (x, y) et interpréter.

Calculons les deux moyennes ($n = 5$) :

$$\bar{x} = \frac{1 + 5 + 10 + 15 + 20}{5} = \frac{51}{5} = 10,2$$

$$\bar{y} = \frac{2500 + 11\,500 + 21\,000 + 30\,000 + 36\,000}{5} = \frac{101\,000}{5} = 20\,200$$

Calculons la covariance avec $\text{Cov}(X, Y) = \overline{xy} - \bar{x}\bar{y}$.

Les produits $x_i y_i$ valent : 2500 ; 57 500 ; 210 000 ; 450 000 ; 720 000.

$$\overline{xy} = \frac{1\,440\,000}{5} = 288\,000$$

$$\text{Cov}(X, Y) = 288\,000 - 10,2 \times 20\,200 = 288\,000 - 206\,040 = 81\,960$$

Calculons les deux variances avec $V = \overline{u^2} - \bar{u}^2$:

$$\overline{x^2} = \frac{1 + 25 + 100 + 225 + 400}{5} = \frac{751}{5} = 150,2$$

$$V(X) = 150,2 - 10,2^2 = 150,2 - 104,04 = 46,16 \text{ et } \sigma(X) \approx 6,7941.$$

$$\overline{y^2} = \frac{2\,775\,500\,000}{5} = 555\,100\,000$$

$$V(Y) = 555\,100\,000 - 20\,200^2 = 147\,060\,000 \text{ et } \sigma(Y) \approx 12\,126,83.$$

Appliquons $r = \frac{\text{Cov}(X, Y)}{\sigma(X)\sigma(Y)}$:

$$r \approx \frac{81\,960}{6,7941 \times 12\,126,83} \approx \frac{81\,960}{82\,391,1} \approx 0,9948$$

$$r \approx 0,9948$$

Interprétons : $r > 0$ et $|r|$ est très proche de 1 (bien au-dessus du seuil $\frac{\sqrt{3}}{2} \approx 0,87$).

⇒ la corrélation est positive et très forte : le prix croît avec le nombre d'inscrits et les points sont presque alignés, un ajustement affine est pleinement justifié

1) b) Par la méthode des moindres carrés, donner une équation de la droite de régression de y en x .

Méthode : droite des moindres carrés de y en x : $y = ax + b$ avec $a = \frac{\text{Cov}(X, Y)}{V(X)}$, puis $b = \bar{y} - a\bar{x}$.

Déterminons la pente :

$$a = \frac{81\,960}{46,16} \approx 1775,5633$$

Déterminons l'ordonnée à l'origine :

$$b = 20\,200 - 1775,5633 \times 10,2 \approx 20\,200 - 18\,110,7457 \approx 2089,2548$$

$$y = 1775,5633x + 2089,2548$$

Interprétons la pente : chaque inscrit supplémentaire coûte environ 1776 dinars ; $b \approx 2089$ dinars représente la part fixe de la facture.

Vérifions que $G(10,2 ; 20\,200)$ appartient à la droite : $1775,5633 \times 10,2 + 2089,2548 \approx 20\,200$. ✓

2) a) Une société de jeux vidéo qui compte 17 ingénieurs veut les former. Estimer le coût de formation selon l'ajustement précédent.

Remplaçons x par 17 dans la droite de régression :

$$y = 1775,5633 \times 17 + 2089,2548$$

$$y \approx 30\,184,576 + 2089,255 \approx 32\,273,83$$

Le coût estimé de la formation des 17 ingénieurs est d'environ 32 274 dinars.

Remarquons que 17 appartient à l'intervalle $[1; 20]$ des valeurs observées : il s'agit d'une interpolation, donc d'une estimation fiable.

2) b) On propose l'ajustement de x en y : $x = 0,0006y + 1,0579$. La somme de 30 096,500 dinars permet-elle de former les 17 ingénieurs ?

Méthode : la question porte sur le nombre d'inscrits que finance une somme donnée : c'est x que l'on cherche à partir de y , donc on utilise la droite de régression de x en y , et non celle de 1) b).

Remplaçons y par 30 096,5 :

$$x = 0,0006 \times 30\,096,5 + 1,0579$$

$$x = 18,0579 + 1,0579 = 19,1158$$

$\Rightarrow x \approx 19,12$, **soit 19 inscrits finançables**

Comparons : $19 > 17$.

Oui : la somme de 30 096,500 dinars suffit largement, elle couvrirait même la formation de 19 ingénieurs.

Attention : on ne pouvait pas répondre en remplaçant $x = 17$ dans la droite de 1) b) et en comparant à 30 096,5 — cela donnerait $32\,274 > 30\,096,5$, donc la réponse *inverse*. Les deux droites de régression sont distinctes ; c'est celle imposée par l'énoncé qu'il faut utiliser.

Corrigé — Exercice 9

1) Calculer r (arrondi à 10^{-4}). Un ajustement affine est-il justifié ?

Calculons les deux moyennes ($n = 5$) :

$$\bar{x} = \frac{100 + 150 + 200 + 300 + 500}{5} = \frac{1250}{5} = 250$$

$$\bar{y} = \frac{0,7 + 1 + 1,2 + 1,6 + 2,3}{5} = \frac{6,8}{5} = 1,36$$

Calculons la covariance avec $\text{Cov}(X, Y) = \overline{xy} - \bar{x}\bar{y}$.

Les produits $x_i y_i$ valent : 70 ; 150 ; 240 ; 480 ; 1150, de somme 2090.

$$\overline{xy} = \frac{2090}{5} = 418, \text{ donc } \text{Cov}(X, Y) = 418 - 250 \times 1,36 = 418 - 340 = 78.$$

Calculons les deux variances avec $V = \overline{u^2} - \bar{u}^2$:

$$\overline{x^2} = \frac{10\,000 + 22\,500 + 40\,000 + 90\,000 + 250\,000}{5} = \frac{412\,500}{5} = 82\,500$$

d'où $V(X) = 82\,500 - 250^2 = 82\,500 - 62\,500 = 20\,000$ et $\sigma(X) = 100\sqrt{2} \approx 141,4214$.

$$\overline{y^2} = \frac{0,49 + 1 + 1,44 + 2,56 + 5,29}{5} = \frac{10,78}{5} = 2,156$$

d'où $V(Y) = 2,156 - 1,36^2 = 2,156 - 1,8496 = 0,3064$ et $\sigma(Y) \approx 0,5535$.

Appliquons $r = \frac{\text{Cov}(X, Y)}{\sigma(X)\sigma(Y)}$:

$$r \approx \frac{78}{141,4214 \times 0,5535} \approx \frac{78}{78,2815} \approx 0,9964$$

$$r \approx 0,9964$$

Comparons au seuil usuel : $0,9964 > \frac{\sqrt{3}}{2} \approx 0,87$.

$\Rightarrow |r|$ est très proche de 1 : les points sont presque alignés, l'ajustement affine est justifié

2) Déterminer la droite de régression de y en x .

Méthode : droite des moindres carrés de y en x : $y = ax + b$ avec $a = \frac{\text{Cov}(X, Y)}{V(X)}$, puis $b = \bar{y} - a\bar{x}$.

Déterminons la pente :

$$a = \frac{78}{20\,000} = 0,0039$$

Déterminons l'ordonnée à l'origine :

$$b = \bar{y} - a\bar{x} = 1,36 - 0,0039 \times 250 = 1,36 - 0,975 = 0,385$$

$$y = 0,0039x + 0,385$$

Interprétons la pente : chaque unité supplémentaire de x fait gagner 0,0039 unité de y .

3) Estimer le rendement pour $x = 650$.

Remplaçons x par 650 dans l'équation de la droite de régression :

$$y = 0,0039 \times 650 + 0,385$$

$$y = 2,535 + 0,385 = 2,92$$

$$y = 2,92$$

Attention : 650 est en dehors de l'intervalle $[100; 500]$ des valeurs observées. Il s'agit d'une extrapolation : l'estimation n'est valable que si le modèle affine reste pertinent au-delà des données.

4) Vérifier par le calcul que le point moyen G appartient à la droite de régression.

Méthode : par construction $b = \bar{y} - a\bar{x}$, donc $a\bar{x} + b = \bar{y}$: le point moyen $G(\bar{x}; \bar{y})$ appartient toujours à la droite de régression. Ce calcul est donc un contrôle de cohérence des valeurs de a et b .

Le point moyen est $G(250; 1,36)$.

Remplaçons x par 250 :

$$0,0039 \times 250 + 0,385 = 0,975 + 0,385 = 1,36 = \bar{y} \quad \checkmark$$

$\Rightarrow G$ appartient bien à la droite de régression

5) Quelle masse d'engrais faut-il viser pour un rendement estimé de 2 ?

Méthode : ici y est connu et x est cherché : on résout l'équation $ax + b = y$ (le sujet n'ayant pas fourni la droite de régression de x en y).

Réolvons $0,0039x + 0,385 = 2$:

$$0,0039x = 2 - 0,385 = 1,615$$

$$x = \frac{1,615}{0,0039} \approx 414,10$$

Il faut viser $x \approx 414$ pour obtenir un rendement estimé de 2.

Vérifions : $0,0039 \times 414,10 + 0,385 \approx 1,615 + 0,385 = 2. \quad \checkmark$

Corrigé — Exercice 10

1) Calculer r (arrondi à 10^{-2}).

Calculons les deux moyennes ($n = 5$) :

$$\bar{x} = \frac{0 + 1 + 2 + 3 + 4}{5} = \frac{10}{5} = 2$$

$$\bar{y} = \frac{2,1 + 3,9 + 6,1 + 7,8 + 10,2}{5} = \frac{30,1}{5} = 6,02$$

Calculons la covariance avec $\text{Cov}(X, Y) = \overline{xy} - \bar{x}\bar{y}$.

Les produits $x_i y_i$ valent : 0 ; 3,9 ; 12,2 ; 23,4 ; 40,8, de somme 80,3.

$$\overline{xy} = \frac{80,3}{5} = 16,06, \text{ donc } \text{Cov}(X, Y) = 16,06 - 2 \times 6,02 = 16,06 - 12,04 = 4,02.$$

Calculons les deux variances avec $V = \overline{u^2} - \bar{u}^2$:

$$\overline{x^2} = \frac{0 + 1 + 4 + 9 + 16}{5} = \frac{30}{5} = 6$$

$$V(X) = 6 - 2^2 = 2 \text{ et } \sigma(X) = \sqrt{2} \approx 1,4142.$$

$$\overline{y^2} = \frac{4,41 + 15,21 + 37,21 + 60,84 + 104,04}{5} = \frac{221,71}{5} = 44,342$$

$$\text{d'où } V(Y) = 44,342 - 6,02^2 = 44,342 - 36,2404 = 8,1016 \text{ et } \sigma(Y) \approx 2,8463.$$

$$\text{Appliquons } r = \frac{\text{Cov}(X, Y)}{\sigma(X)\sigma(Y)} :$$

$$r \approx \frac{4,02}{1,4142 \times 2,8463} \approx \frac{4,02}{4,0253} \approx 0,9987$$

$$r \approx 1,00$$

Attention : r vaut 0,9987 et non 1 ; c'est son *arrondi* à 10^{-2} qui vaut 1,00. Un coefficient de corrélation est toujours tel que $|r| \leq 1$, avec égalité seulement si les points sont exactement alignés.

$\Rightarrow |r|$ est très proche de 1 : le nuage est quasiment aligné, l'ajustement affine est pleinement justifié

2) Déterminer la droite de régression de y en x .

Méthode : droite des moindres carrés de y en x : $y = ax + b$ avec $a = \frac{\text{Cov}(X, Y)}{V(X)}$, puis $b = \bar{y} - a\bar{x}$.

Déterminons la pente :

$$a = \frac{4,02}{2} = 2,01$$

Déterminons l'ordonnée à l'origine :

$$b = \bar{y} - a\bar{x} = 6,02 - 2,01 \times 2 = 6,02 - 4,02 = 2$$

$$y = 2,01x + 2$$

3) Estimer y pour $x = 6$.

Remplaçons x par 6 dans l'équation obtenue :

$$y = 2,01 \times 6 + 2 = 12,06 + 2 = 14,06$$

$$y \approx 14,06$$

4) Vérifier que le point moyen appartient à la droite de régression.

Méthode : comme $b = \bar{y} - a\bar{x}$, on a toujours $a\bar{x} + b = \bar{y}$: le point moyen $G(\bar{x}; \bar{y})$ est toujours sur la droite de régression.

Le calcul sert ici de contrôle de a et de b .

Le point moyen est $G(2; 6,02)$.

Remplaçons x par 2 :

$$2,01 \times 2 + 2 = 4,02 + 2 = 6,02 = \bar{y} \quad \checkmark$$

$\Rightarrow G(2; 6,02)$ appartient bien à la droite de régression

5) À partir de quelle valeur de x l'estimation de y dépasse-t-elle 15?

Réolvons l'inéquation $2,01x + 2 > 15$:

$$2,01x > 13$$

$$x > \frac{13}{2,01} \quad (\text{on divise par } 2,01 > 0 : \text{le sens de l'inégalité est conservé})$$

$$\frac{13}{2,01} \approx 6,47$$

$$x > 6,47$$

Vérifions aux bornes : pour $x = 6$, $y \approx 14,06 < 15$; pour $x = 7$, $y = 2,01 \times 7 + 2 = 16,07 > 15$. $\checkmark$

L'estimation dépasse 15 dès que $x > 6,47$, donc à partir de $x = 7$ si x est entier.

Corrigé — Exercice 11 — Bac contrôle 2015

1) Représenter le nuage de points $(x_i; y_i)$.

Plaçons les sept points : $(1; 229)$, $(2; 285)$, $(3; 366)$, $(4; 478)$, $(5; 630)$, $(6; 808)$ et $(7; 1031)$.

Les unités sont différentes sur les deux axes (1 rang en abscisse, 100 millions en ordonnée) pour que le nuage occupe toute la figure.

Observons l'allure : les écarts successifs (56, 81, 112, 152, 178, 223) *augmentent*, alors que les rangs progressent régulièrement.

⇒ le nuage n'est pas aligné : sa croissance s'accélère, ce qui suggère un modèle exponentiel plutôt qu'affine (voir la figure ci-dessous)

2) a) Donner l'arrondi à 10^{-4} du coefficient de corrélation de la série (X, Z) . En déduire qu'un ajustement affine de (X, Z) est justifié.

Méthode : on ne travaille plus sur y mais sur $z = \ln y$: si (X, Z) est bien ajusté par une droite, alors $y = e^z$ suit un modèle exponentiel. C'est le principe de l'ajustement exponentiel.

Calculons les deux moyennes ($n = 7$) :

$$\bar{x} = \frac{1 + 2 + 3 + 4 + 5 + 6 + 7}{7} = \frac{28}{7} = 4$$

$$\bar{z} = \frac{5,43 + 5,65 + 5,90 + 6,17 + 6,45 + 6,69 + 6,94}{7} = \frac{43,23}{7} \approx 6,1757$$

Calculons la covariance avec $\text{Cov}(X, Z) = \overline{xz} - \bar{x}\bar{z}$.

Les produits $x_i z_i$ valent : 5,43; 11,30; 17,70; 24,68; 32,25; 40,14; 48,58, de somme 180,08.

$$\overline{xz} = \frac{180,08}{7} \approx 25,7257$$

$$\text{Cov}(X, Z) \approx 25,7257 - 4 \times 6,1757 \approx 25,7257 - 24,7029 \approx 1,0229$$

Calculons les deux variances avec $V = \overline{u^2} - \bar{u}^2$:

$$\overline{x^2} = \frac{1 + 4 + 9 + 16 + 25 + 36 + 49}{7} = \frac{140}{7} = 20, \text{ donc } V(X) = 20 - 4^2 = 4 \text{ et } \sigma(X) = 2.$$

$$\overline{z^2} = \frac{268,8085}{7} \approx 38,4012$$

$$V(Z) \approx 38,4012 - 6,1757^2 \approx 0,2618 \text{ et } \sigma(Z) \approx 0,5116.$$

Appliquons $r = \frac{\text{Cov}(X, Z)}{\sigma(X)\sigma(Z)}$:

$$r \approx \frac{1,0229}{2 \times 0,5116} \approx \frac{1,0229}{1,0233} \approx 0,9996$$

$$r \approx 0,9996$$

Comparons au seuil usuel : $0,9996 > \frac{\sqrt{3}}{2} \approx 0,87$.

⇒ $|r|$ est quasiment égal à 1 : les points $(x_i; z_i)$ sont presque parfaitement alignés, l'ajustement affine de (X, Z) est justifié

2) b) Déterminer une équation de la droite de régression de z en x (coefficients arrondis au centième).

Méthode : droite des moindres carrés de z en x : $z = ax + b$ avec $a = \frac{\text{Cov}(X, Z)}{V(X)}$, puis $b = \bar{z} - a\bar{x}$.

Déterminons la pente :

$$a = \frac{1,0229}{4} \approx 0,2557$$

Déterminons l'ordonnée à l'origine :

$$b = \bar{z} - a\bar{x} \approx 6,1757 - 0,2557 \times 4 \approx 6,1757 - 1,0229 \approx 5,1529$$

$$z = 0,25x + 5,15$$

Attention aux arrondis : la pente exacte vaut 0,2557. Le sujet retient au centième les coefficients $a = 0,25$ et $b = 5,15$ (valeurs tronquées) — ce sont eux qui donnent la relation imposée à la question 3). C'est donc ce modèle que l'on conserve pour toute la suite.

3) a) Établir la relation $y = 172,43 e^{0,25x}$.

Méthode : pour revenir de z à y , on compose par l'exponentielle : $z = \ln y \iff y = e^z$, puis on sépare les exposants avec $e^{u+v} = e^u \times e^v$.

Partons de la droite obtenue : $z = 0,25x + 5,15$.

Comme $z = \ln y$ avec $y > 0$, on a $y = e^z$.

$$y = e^{0,25x+5,15} = e^{5,15} \times e^{0,25x}$$

Calculons $e^{5,15} \approx 172,4315 \approx 172,43$.

$$y = 172,43 e^{0,25x}$$

Vérifions la cohérence sur une donnée, pour $x = 4$: $172,43 e^1 \approx 172,43 \times 2,7183 \approx 468,7$, à comparer à la valeur observée $y_4 = 478$: l'écart est inférieur à 2 %, le modèle restitue bien les données. ✓

3) b) Estimer, selon ce modèle, la population de l'Afrique en 2030.

Déterminons d'abord le rang de l'année 2030.

Le rang 1 correspond à 1950 et chaque rang vaut 10 ans, donc le rang de 2030 est $x = \frac{2030 - 1950}{10} + 1 = 8 + 1 = 9$.

Remplaçons x par 9 dans le modèle :


$$y = 172,43 e^{0,25 \times 9} = 172,43 e^{2,25}$$

$$e^{2,25} \approx 9,4877, \text{ donc } y \approx 172,43 \times 9,4877 \approx 1635,97$$

Environ 1636 millions d'habitants en 2030.

Soit près de 1,64 milliard d'habitants — un peu plus du triple de la population de 1980 (rang 4).

Remarquons la sensibilité du modèle exponentiel aux arrondis : avec les coefficients non tronqués ($a \approx 0,2557$ et $b \approx 5,1529$) on obtiendrait $y \approx 1727$ millions, soit 91 millions d'écart. Dans une extrapolation exponentielle, une petite erreur sur la pente est amplifiée par l'exponentielle.



Corrigé Ex 11 : nuage de la population (allure exponentielle).

Corrigé — Exercice 12 — Bac contrôle 2019

1) a) Série (t, x) : donner le coefficient de corrélation.

Calculons les deux moyennes ($n = 5$) :

$$\bar{t} = \frac{2011 + 2012 + 2013 + 2014 + 2015}{5} = \frac{10\,065}{5} = 2013$$

$$\bar{x} = \frac{80 + 103 + 128 + 154 + 159}{5} = \frac{624}{5} = 124,8$$

Calculons la covariance. Les années étant en progression arithmétique, il est plus simple de centrer t : on pose $u_i = t_i - 2013$, soit $u = -2 ; -1 ; 0 ; 1 ; 2$.

$$\text{Cov}(t, x) = \frac{1}{5} \sum u_i x_i = \frac{-160 - 103 + 0 + 154 + 318}{5} = \frac{209}{5} = 41,8$$

Calculons les deux variances :

$$V(t) = \frac{4 + 1 + 0 + 1 + 4}{5} = \frac{10}{5} = 2, \text{ donc } \sigma(t) = \sqrt{2} \approx 1,4142.$$

$$\overline{x^2} = \frac{6400 + 10\,609 + 16\,384 + 23\,716 + 25\,281}{5} = \frac{82\,390}{5} = 16\,478$$

$$\text{d'où } V(x) = 16\,478 - 124,8^2 = 16\,478 - 15\,575,04 = 902,96 \text{ et } \sigma(x) \approx 30,0493.$$

Appliquons $r = \frac{\text{Cov}(t, x)}{\sigma(t) \sigma(x)}$:

$$r \approx \frac{41,8}{1,4142 \times 30,0493} \approx \frac{41,8}{42,4970} \approx 0,98$$

$$r \approx 0,98$$

$\Rightarrow 0,98 > \frac{\sqrt{3}}{2} \approx 0,87$: la corrélation est forte et positive, l'ajustement affine de (t, x) est justifié

1) b) Déterminer la droite de régression de x en t .

Méthode : droite des moindres carrés de x en t : $x = at + b$ avec $a = \frac{\text{Cov}(t, x)}{V(t)}$, puis $b = \bar{x} - a\bar{t}$.

Déterminons la pente :

$$a = \frac{41,8}{2} = 20,9$$

Déterminons l'ordonnée à l'origine :

$$b = \bar{x} - a\bar{t} = 124,8 - 20,9 \times 2013 = 124,8 - 42\,071,7 = -41\,946,9$$

$$x = 20,9t - 41\,946,9$$

Interprétons la pente : le nombre d'abonnés augmente d'environ 20,9 pour 1000 habitants chaque année.

Attention : b n'a ici aucun sens concret (ce serait le nombre d'abonnés en l'an 0) ; c'est le prix à payer quand on garde les années brutes comme variable.

1) c) Donner une prévision de x pour l'année $t = 2020$.

Remplaçons t par 2020 :

$$x = 20,9 \times 2020 - 41\,946,9$$

$$x = 42\,218 - 41\,946,9 = 271,1$$

En 2020, on prévoit environ 271 abonnés à Internet pour 1000 habitants.

2) a) On pose $z = \ln y$. Série (x, z) : donner le coefficient de corrélation.

Calculons la moyenne de z ($\bar{x} = 124,8$ est déjà connue) :

$$\bar{z} = \frac{4,094 + 4,413 + 4,500 + 4,868 + 5,193}{5} = \frac{23,068}{5} = 4,6136$$

Calculons la covariance avec $\text{Cov}(x, z) = \bar{xz} - \bar{x}\bar{z}$.

Les produits $x_i z_i$ valent : 327,520 ; 454,539 ; 576 ; 749,672 ; 825,687, de somme 2933,418.

$$\bar{xz} = \frac{2933,418}{5} = 586,6836$$

$$\text{Cov}(x, z) = 586,6836 - 124,8 \times 4,6136 = 586,6836 - 575,7773 \approx 10,9063$$

Calculons la variance de z :

$$\overline{z^2} = \frac{107,150078}{5} \approx 21,4300$$

$$V(z) \approx 21,4300 - 4,6136^2 \approx 0,1447 \text{ et } \sigma(z) \approx 0,3804.$$

Appliquons $r = \frac{\text{Cov}(x, z)}{\sigma(x)\sigma(z)}$ avec $\sigma(x) \approx 30,0493$:

$$r \approx \frac{10,9063}{30,0493 \times 0,3804} \approx \frac{10,9063}{11,4310} \approx 0,95$$

$$r \approx 0,95$$

2) b) Justifier l'ajustement affine.

Comparons $|r|$ au seuil usuel : $0,95 > \frac{\sqrt{3}}{2} \approx 0,87$.

$\Rightarrow$ la corrélation entre x et z est forte : l'ajustement affine de la série (x, z) est justifié, donc l'ajustement exponentiel de (x, y) l'est aussi

2) c) Déterminer la droite de régression de z en x .

Déterminons la pente :

$$a = \frac{\text{Cov}(x, z)}{V(x)} = \frac{10,9063}{902,96} \approx 0,0121$$

Déterminons l'ordonnée à l'origine (avec la pente non arrondie 0,012078) :

$$b = \bar{z} - a\bar{x} \approx 4,6136 - 0,012078 \times 124,8 \approx 4,6136 - 1,5074 \approx 3,106$$

$$z = 0,0121x + 3,106$$

2) d) Établir la relation $y = Ae^{Bx}$ (A et B à déterminer).

Méthode : on revient de z à y par l'exponentielle : $z = \ln y \iff y = e^z$, puis $e^{u+v} = e^u \times e^v$.

Partons de $z = 0,0121x + 3,106$ avec $z = \ln y$ et $y > 0$:

$$y = e^z = e^{0,0121x+3,106} = e^{3,106} \times e^{0,0121x}$$

Calculons $e^{3,106} \approx 22,33$.

$$y = 22,33 e^{0,0121x} \quad \text{soit} \quad A \approx 22,33 \text{ et } B = 0,0121$$

3) Donner une prévision de la largeur de bande y pour l'année $t = 2020$.

Méthode : les deux modèles s'enchaînent : la question 1) c) donne x à partir de t , la question 2) d) donne y à partir de x .

On ne peut pas passer directement de t à y .

Reprenons la prévision de 1) c) : pour $t = 2020$, $x \approx 271$.

Remplaçons x par 271 dans le modèle exponentiel :

$$y = 22,33 e^{0,0121 \times 271} = 22,33 e^{3,2791}$$

$$e^{3,2791} \approx 26,55, \text{ donc } y \approx 22,33 \times 26,55 \approx 592,9$$

En 2020, la largeur de bande passante prévue est d'environ 593 Gb/s.

Attention : il s'agit d'une double extrapolation ($t = 2020$ est hors de $[2011 ; 2015]$, puis $x \approx 271$ est hors de $[80 ; 159]$). Les erreurs se cumulent et sont amplifiées par l'exponentielle : la prévision doit être lue comme un ordre de grandeur.

Corrigé — Exercice 13

I. 1) Par la méthode des moindres carrés, déterminer la droite Δ de régression de P en X . (Résultats arrondis à 10^{-1} près.)

Méthode : droite des moindres carrés de P en X : $P = aX + b$ avec $a = \frac{\text{Cov}(X, P)}{V(X)}$, puis $b = \bar{P} - a\bar{x}$.

Calculons les deux moyennes ($n = 7$) :

$$\bar{x} = \frac{1 + 3 + 5 + 7 + 9 + 11 + 12}{7} = \frac{48}{7} \approx 6,8571$$

$$\bar{P} = \frac{93 + 74 + 60 + 50 + 41 + 33 + 30}{7} = \frac{381}{7} \approx 54,4286$$

Calculons la covariance avec $\text{Cov}(X, P) = \overline{XP} - \bar{x}\bar{P}$.

Les produits $X_i P_i$ valent : 93 ; 222 ; 300 ; 350 ; 369 ; 363 ; 360, de somme 2057.

$$\overline{XP} = \frac{2057}{7} \approx 293,8571$$

$$\text{Cov}(X, P) \approx 293,8571 - 6,8571 \times 54,4286 \approx 293,8571 - 373,2245 \approx -79,3673$$

Calculons la variance de X :

$$\overline{X^2} = \frac{1 + 9 + 25 + 49 + 81 + 121 + 144}{7} = \frac{430}{7} \approx 61,4286$$

$$V(X) \approx 61,4286 - 6,8571^2 \approx 61,4286 - 47,0204 \approx 14,4082$$

Déterminons la pente :

$$a = \frac{-79,3673}{14,4082} \approx -5,5085 \approx -5,5$$

Déterminons l'ordonnée à l'origine (avec la pente non arrondie) :

$$b \approx 54,4286 - (-5,5085) \times 6,8571 \approx 54,4286 + 37,7726 \approx 92,2011 \approx 92,2$$

$$\Delta : P = -5,5 X + 92,2$$

Interprétons : la pente est négative, chaque couche de compression supplémentaire fait perdre environ 5,5 points de pourcentage.

Vérifions que le point moyen $G(6,9 ; 54,4)$ appartient à Δ : $-5,5 \times 6,8571 + 92,2 \approx -37,71 + 92,2 \approx 54,5 \approx \bar{P}$. ✓

I. 2) Estimer le pourcentage pour une épaisseur de 14 cm.

Remplaçons X par 14 dans l'équation de Δ :

$$P = -5,5 \times 14 + 92,2$$

$$P = -77 + 92,2 = 15,2$$

$$P \approx 15,2 \%$$

Attention : avec les coefficients non arrondis ($a \approx -5,5085$ et $b \approx 92,2011$) on trouverait 15,1 %. L'écart provient uniquement des arrondis demandés à 10^{-1} .

Remarquons aussi la limite du modèle affine : pour $X = 17$ il donnerait une valeur *négative*, ce qui est impossible pour un pourcentage. C'est ce défaut que corrige le modèle exponentiel de la partie II.

II. 1) Déterminer à 10^{-4} le coefficient de corrélation r de (X, Y) avec $Y = \ln P$. Un ajustement affine est-il justifié ?

Calculons la moyenne de Y ($\bar{x} \approx 6,8571$ est déjà connue) :

$$\bar{Y} = \frac{4,53 + 4,30 + 4,09 + 3,91 + 3,71 + 3,50 + 3,40}{7} = \frac{27,44}{7} = 3,92$$

Calculons la covariance avec $\text{Cov}(X, Y) = \overline{XY} - \bar{x}\bar{Y}$.

Les produits $X_i Y_i$ valent : 4,53 ; 12,90 ; 20,45 ; 27,37 ; 33,39 ; 38,50 ; 40,80, de somme 177,94.

$$\overline{XY} = \frac{177,94}{7} \approx 25,42$$

$$\text{Cov}(X, Y) \approx 25,42 - 6,8571 \times 3,92 \approx 25,42 - 26,88 \approx -1,46$$

Calculons les deux écarts-types :

$$V(X) \approx 14,4082 \text{ (partie I), donc } \sigma(X) \approx 3,7958.$$

$$\overline{Y^2} = \frac{108,6012}{7} \approx 15,5145$$

$$V(Y) \approx 15,5145 - 3,92^2 \approx 0,1481 \text{ et } \sigma(Y) \approx 0,3848.$$

Appliquons $r = \frac{\text{Cov}(X, Y)}{\sigma(X) \sigma(Y)} :$

$$r \approx \frac{-1,46}{3,7958 \times 0,3848} \approx \frac{-1,46}{1,4605} \approx -0,9996$$

$$r \approx -0,9996$$

Comparons au seuil usuel : $|r| = 0,9996 > \frac{\sqrt{3}}{2} \approx 0,87.$

$\Rightarrow$ **l'ajustement affine de (X, Y) est justifié, et il est meilleur que celui de la partie I où $|r| \approx 0,98$ seulement**

II. 2) On admet que $Y = -0,1X + 4,61$. Déterminer le réel β (arrondi à l'unité) tel que

$$P = \beta e^{-0,1X}.$$

Méthode : on revient de Y à P par l'exponentielle : $Y = \ln P \iff P = e^Y$, puis $e^{u+v} = e^u \times e^v$.

Partons de $Y = \ln P = -0,1X + 4,61$ avec $P > 0$:

$$P = e^Y = e^{-0,1X+4,61} = e^{4,61} \times e^{-0,1X}$$

Identifions : $\beta = e^{4,61} \approx 100,4842$, soit $\beta \approx 100$ à l'unité près.

$$\beta = 100 \quad \text{donc} \quad P = 100 e^{-0,1X}$$

Vérifions sur la première donnée, pour $X = 1$: $100 e^{-0,1} \approx 100 \times 0,9048 \approx 90,5$, à comparer à $P_1 = 93$. ✓

II. 3) Selon ce modèle, estimer le pourcentage pour une épaisseur de 20 cm.

Remplaçons X par 20 dans $P = 100 e^{-0,1X}$:

$$P = 100 e^{-0,1 \times 20} = 100 e^{-2}$$

$$e^{-2} \approx 0,1353, \text{ donc } P \approx 13,53$$

Selon le modèle exponentiel, il resterait environ 13,5 % pour une épaisseur de 20 cm.

Remarquons que ce modèle reste strictement positif quel que soit X : contrairement au modèle affine, il ne prédit jamais de pourcentage négatif. C'est un argument décisif en sa faveur.

Corrigé — Exercice 14

1) a) Représenter le nuage de points.

Plaçons les onze points $M_i(x_i; y_i)$, de $(16,5; 10)$ à $(41,7; 3,2)$.

L'axe des abscisses commence à 15 (et non à 0) pour que le nuage occupe toute la largeur de la figure.

Observons l'allure : y décroît quand x croît, mais la décroissance *ralentit* — le nuage est incurvé, il n'est pas exactement aligné (voir la figure ci-dessous).

⇒ le nuage est décroissant et légèrement courbé

1) b) Déterminer le coefficient de corrélation entre x et y .

Calculons les deux moyennes ($n = 11$) :

$$\bar{x} = \frac{305}{11} \approx 27,73$$

$$\bar{y} = \frac{65,7}{11} \approx 5,97$$

Calculons la covariance avec $\text{Cov}(X, Y) = \overline{xy} - \bar{x}\bar{y}$.

$$\sum x_i y_i = 1636,84, \text{ donc } \overline{xy} = \frac{1636,84}{11} \approx 148,80.$$

$$\text{Cov}(X, Y) \approx 148,8036 - 27,7273 \times 5,9727 \approx 148,8036 - 165,6074 \approx -16,80$$

Calculons les deux variances avec $V = \overline{u^2} - \bar{u}^2$:

$$\overline{x^2} = \frac{9176,18}{11} \approx 834,1982$$

$$V(X) \approx 834,1982 - 768,8017 \approx 65,40 \text{ et } \sigma(X) \approx 8,09.$$

$$\overline{y^2} = \frac{443,99}{11} \approx 40,3627$$

$$V(Y) \approx 40,3627 - 35,6736 \approx 4,69 \text{ et } \sigma(Y) \approx 2,17.$$

Appliquons $r = \frac{\text{Cov}(X, Y)}{\sigma(X)\sigma(Y)}$:

$$r \approx \frac{-16,80}{8,0868 \times 2,1655} \approx \frac{-16,80}{17,5120} \approx -0,96$$

$$r \approx -0,96$$

⇒ $r < 0$: la corrélation est négative (à x grand correspond y petit) et $|r| = 0,96 > \frac{\sqrt{3}}{2} \approx 0,87$, l'ajustement affine est acceptable

1) c) Déterminer une équation de la droite D de régression de y en x .

Méthode : droite des moindres carrés de y en x : $y = ax + b$ avec $a = \frac{\text{Cov}(X, Y)}{V(X)}$, puis $b = \bar{y} - a\bar{x}$.

Déterminons la pente :

$$a = \frac{-16,8038}{65,3965} \approx -0,2570 \approx -0,26$$

Déterminons l'ordonnée à l'origine (avec la pente non arrondie) :

$$b \approx 5,9727 - (-0,2570) \times 27,7273 \approx 5,9727 + 7,1246 \approx 13,0973 \approx 13,10$$

$$D : y = -0,26x + 13,10$$

1) d) Déterminer la charge maximale pour une flèche de 26 m.

Remplaçons x par 26 dans l'équation de D :

$$y = -0,26 \times 26 + 13,10$$

$$y = -6,76 + 13,10 = 6,34$$

$$y \approx 6,34 \text{ Mo/s}$$

Attention : avec les coefficients non arrondis ($a \approx -0,2570$ et $b \approx 13,0973$) on obtiendrait 6,42. L'écart vient des arrondis à 10^{-2} demandés par l'énoncé.

2) a) On pose $Z = \frac{1}{y}$. Déterminer le coefficient de corrélation de (x, z) .

Méthode : quand un nuage est courbé, on cherche un changement de variable qui le redresse. Ici on essaie $Z = \frac{1}{y}$: si (x, Z) est aligné, alors $y = \frac{1}{ax+b}$, modèle dit hyperbolique.

Calculons les valeurs de $z_i = \frac{1}{y_i}$:

0,1; 0,1111; 0,125; 0,1429; 0,1667; 0,1818; 0,2; 0,2222; 0,25; 0,2857; 0,3125.

Calculons la moyenne : $\bar{z} = \frac{2,0979}{11} \approx 0,1907$.

Calculons la covariance : $\sum x_i z_i \approx 64,1788$, donc $\overline{xz} \approx 5,8344$.

$\text{Cov}(x, z) \approx 5,8344 - 27,7273 \times 0,1907 \approx 5,8344 - 5,2881 \approx 0,5464$

Calculons la variance de z :

$\overline{z^2} \approx 0,040944$

$V(z) \approx 0,040944 - 0,1907^2 \approx 0,004571$ et $\sigma(z) \approx 0,0676$.

Appliquons $r = \frac{\text{Cov}(x, z)}{\sigma(x) \sigma(z)}$ avec $\sigma(x) \approx 8,0868$:

$$r \approx \frac{0,5464}{8,0868 \times 0,0676} \approx \frac{0,5464}{0,5467} \approx 0,9993$$

$$r \approx 0,9993$$

$\Rightarrow |r|$ est bien plus proche de 1 qu'en 1) b) (0,96) : le changement de variable a effectivement redressé le nuage

2) b) Exprimer Z en fonction de X (coefficients arrondis à 10^{-4}).

Déterminons la pente :

$$a = \frac{\text{Cov}(x, z)}{V(x)} = \frac{0,5464}{65,3965} \approx 0,008355 \approx 0,0084$$

Déterminons l'ordonnée à l'origine (avec la pente non arrondie) :

$$b = \bar{z} - a \bar{x} \approx 0,1907 - 0,008355 \times 27,7273 \approx 0,1907 - 0,2316 \approx -0,0409$$

$$Z = 0,0084 X - 0,0409$$

2) c) Déterminer, selon ce modèle, la charge pour une flèche de 26 m.

Méthode : le modèle donne Z , pas y : il faut revenir à y par $y = \frac{1}{Z}$ — c'est l'étape que l'on oublie le plus souvent.

Calculons d'abord Z pour $X = 26$:

$$Z = 0,0084 \times 26 - 0,0409 = 0,2184 - 0,0409 = 0,1775$$

Revenons à y :

$$y = \frac{1}{Z} = \frac{1}{0,1775} \approx 5,63$$

$$y \approx 5,63 \text{ Mo/s}$$

Comparons aux données : pour $x = 25$ on observe $y = 6$ et pour $x = 27$ on observe $y = 5,5$. La valeur 5,63 est bien encadrée par ces deux observations, alors que le modèle affine donnait $6,34 > 6$. ✓

3) Quel est le modèle le plus pertinent ?

Comparons les deux coefficients de corrélation :


modèle affine : $|r| \approx 0,96$; modèle hyperbolique : $|r| \approx 0,9993$.

Comparons ensuite les prévisions à $x = 26 : 6,34$ pour le modèle affine, alors que les valeurs observées à $x = 25$ et $x = 27$ sont 6 et 5,5 — la droite passe au-dessus du nuage dans cette zone. Le modèle hyperbolique donne 5,63, cohérent avec les données.

Examinons enfin le comportement pour x grand : la droite $y = -0,26x + 13,10$ s'annule pour $x \approx 50,4$ puis devient *négative*, ce qui n'a aucun sens pour un débit. Le modèle $y = \frac{1}{0,0084x - 0,0409}$ lui, reste positif et décroît vers 0.

Le modèle hyperbolique est le plus pertinent.

Il cumule les trois avantages : corrélation quasi parfaite ($|r| \approx 0,9993$), meilleur accord avec les données observées, et comportement admissible pour toute valeur de x .



Corrigé Ex 14 : nuage (courbé) et droite affine $y = -0,26x + 13,10$ — l'ajustement $1/y$ est meilleur.

Corrigé — Exercice 15

1) a) Représenter le nuage de points.

Plaçons les six points $M_i(x_i; y_i)$: $(2; 11)$, $(4; 21)$, $(6; 28)$, $(8; 35)$, $(10; 45)$ et $(12; 52)$.

Observons l'allure : y croît régulièrement avec x et les points sont sensiblement alignés — aucun ne s'écarte nettement des autres.

⇒ le nuage est croissant et pratiquement rectiligne : un ajustement affine est envisageable (voir la figure ci-dessous)

1) b) Déterminer la droite de régression de y en x .

Méthode : droite des moindres carrés de y en x : $y = ax + b$ avec $a = \frac{\text{Cov}(X, Y)}{V(X)}$, puis $b = \bar{y} - a\bar{x}$.

Calculons les deux moyennes ($n = 6$) :

$$\bar{x} = \frac{2 + 4 + 6 + 8 + 10 + 12}{6} = \frac{42}{6} = 7$$

$$\bar{y} = \frac{11 + 21 + 28 + 35 + 45 + 52}{6} = \frac{192}{6} = 32$$

Calculons la covariance à l'aide de $\text{Cov}(X, Y) = \overline{xy} - \bar{x}\bar{y}$.

Les produits $x_i y_i$ valent : 22; 84; 168; 280; 450; 624, de somme 1628.

$$\overline{xy} = \frac{1628}{6} = \frac{814}{3} \approx 271,3333$$

$$\text{Cov}(X, Y) = \frac{814}{3} - 7 \times 32 = \frac{814}{3} - \frac{672}{3} = \frac{142}{3} \approx 47,33$$

Calculons la variance de X avec $V(X) = \overline{x^2} - \bar{x}^2$:

$$\overline{x^2} = \frac{4 + 16 + 36 + 64 + 100 + 144}{6} = \frac{364}{6} = \frac{182}{3}$$

$$V(X) = \frac{182}{3} - 49 = \frac{182 - 147}{3} = \frac{35}{3} \approx 11,67$$

Déterminons la pente :

$$a = \frac{142/3}{35/3} = \frac{142}{35} \approx 4,0571 \approx 4,06$$

Déterminons l'ordonnée à l'origine, avec la valeur exacte de la pente :

$$b = 32 - \frac{142}{35} \times 7 = 32 - \frac{142}{5} = 32 - 28,4 = 3,6$$

$$D : y = 4,06x + 3,6$$

Vérifions que D passe par le point moyen $G(7; 32)$: $4,0571 \times 7 + 3,6 = 28,4 + 3,6 = 32$. ✓

1) c) Estimer les ventes pour un budget de 25.

Remplaçons x par 25 dans l'équation de D :

$$y = 4,06 \times 25 + 3,6 = 101,5 + 3,6 = 105,1$$

Le modèle affine prévoit environ 105 milliers de licences pour un budget de 25 milliers de dinars.

Attention : $x = 25$ est très loin de l'intervalle observé $[2; 12]$. Il s'agit d'une extrapolation lointaine, à prendre avec prudence.

2) a) Étudier le sens de variation de f sur $[12; +\infty[$, où $f(x) = \frac{100x - 160}{x + 8}$.

Méthode : dérivée d'un quotient : $\left(\frac{u}{v}\right)' = \frac{u'v - uv'}{v^2}$.

f est définie sur $[12; +\infty[$ car $x + 8 \geq 20 > 0$; elle y est dérivable comme quotient de fonctions dérivables.

Dérivons avec $u(x) = 100x - 160$ et $v(x) = x + 8$, donc $u'(x) = 100$ et $v'(x) = 1$:

$$f'(x) = \frac{100(x+8) - (100x-160) \times 1}{(x+8)^2}$$

$$100(x+8) - (100x-160) = 100x + 800 - 100x + 160 = 960$$

$$f'(x) = \frac{960}{(x+8)^2}$$

$960 > 0$ et $(x+8)^2 > 0$, donc $f'(x) > 0$ sur tout $[12; +\infty[$.

$\Rightarrow f$ est strictement croissante sur $[12; +\infty[$

Cherchons la limite en $+\infty$: au voisinage de $+\infty$, le quotient a la limite du quotient des termes de plus haut degré,

$$\lim_{x \rightarrow +\infty} f(x) = \lim_{x \rightarrow +\infty} \frac{100x}{x} = 100.$$

$\Rightarrow$ la droite d'équation $y = 100$ est asymptote horizontale à la courbe de f : les ventes *plafonnent* à 100 milliers de licences

2) b) Calculer $f(25)$.

Remplaçons x par 25 :

$$f(25) = \frac{100 \times 25 - 160}{25 + 8} = \frac{2500 - 160}{33} = \frac{2340}{33} = \frac{780}{11}$$

$$f(25) = \frac{780}{11} \approx 70,91$$

Le modèle homographique prévoit environ 71 milliers de licences pour un budget de 25.

2) c) Quel est le modèle le plus pertinent ?


Comparons d'abord les deux prévisions en $x = 25$: 105 milliers pour la droite, 70,91 milliers pour f .

Examinons le comportement pour x grand : la droite $y = 4,06x + 3,6$ croît indéfiniment (elle prévoirait plus de 2000 milliers de licences pour $x = 500$), alors que f croît en restant *bornée* par 100.

Raccordons enfin les deux modèles au bord du domaine : $f(12) = \frac{1200 - 160}{20} = \frac{1040}{20} = 52$, qui est exactement la dernière valeur observée. ✓

Le modèle homographique est le plus pertinent pour les grands budgets.

Économiquement, le marché est borné : au-delà d'un certain budget, la publicité ne peut plus créer de nouveaux clients. Le modèle affine, lui, ignore cette saturation ; il ne reste acceptable que sur l'intervalle observé $[2; 12]$.



Corrigé Ex 15 : nuage et droite de régression $y = 4,06x + 3,6$.

Corrigé — Exercice 16

1) a) Représenter le nuage de points.

Plaçons les sept points $M_i(x_i; y_i)$: (1; 1,26), (2; 1,98), (3; 2,28), (4; 2,62), (5; 2,84), (6; 3) et (7; 3,20).

Observons l'allure : le profit croît toujours, mais de moins en moins vite (+0,72 puis +0,30, +0,34, +0,22, +0,16, +0,20). Le nuage est croissant et *incurvé vers le bas* (concave), il n'est pas aligné.

⇒ **le nuage est croissant à croissance ralentie** (voir la figure ci-après)

1) b) Calculer le coefficient de corrélation.

Calculons les deux moyennes ($n = 7$) :

$$\bar{x} = \frac{1 + 2 + 3 + 4 + 5 + 6 + 7}{7} = \frac{28}{7} = 4$$

$$\bar{y} = \frac{17,18}{7} \approx 2,4543$$

Calculons la covariance avec $\text{Cov}(X, Y) = \overline{xy} - \bar{x}\bar{y}$.

Les produits $x_i y_i$ valent : 1,26; 3,96; 6,84; 10,48; 14,20; 18; 22,40, de somme 77,14.

$$\overline{xy} = \frac{77,14}{7} = 11,02$$

$$\text{Cov}(X, Y) = 11,02 - 4 \times 2,4543 = 11,02 - 9,8171 \approx 1,2029$$

Calculons les deux variances avec $V = \overline{u^2} - \bar{u}^2$:

$$\overline{x^2} = \frac{140}{7} = 20, \text{ donc } V(X) = 20 - 4^2 = 4 \text{ et } \sigma(X) = 2.$$

$$\overline{y^2} = \frac{44,8764}{7} \approx 6,4109$$

$$V(Y) \approx 6,4109 - 2,4543^2 \approx 0,3874 \text{ et } \sigma(Y) \approx 0,6224.$$

Appliquons $r = \frac{\text{Cov}(X, Y)}{\sigma(X)\sigma(Y)}$:

$$r \approx \frac{1,2029}{2 \times 0,6224} \approx \frac{1,2029}{1,2448} \approx 0,9663$$

$$r \approx 0,97$$

⇒ $0,97 > \frac{\sqrt{3}}{2} \approx 0,87$: la corrélation est forte, mais la courbure du nuage invite à chercher un meilleur modèle

2) a) On pose $Z = e^y$. Dresser le tableau statistique $(x_i; z_i)$.

Méthode : quand le nuage est concave, on cherche à le redresser en remontant les grandes valeurs : c'est le rôle de l'exponentielle. Si (x, Z) devient aligné, alors $e^y = ax + b$, donc $y = \ln(ax + b)$ — modèle logarithmique.

Calculons $z_i = e^{y_i}$ (arrondis à 10^{-4}) :

x_i	y_i	$z_i = e^{y_i}$
1	1,26	3,5254
2	1,98	7,2427
3	2,28	9,7767
4	2,62	13,7357
5	2,84	17,1158
6	3	20,0855
7	3,20	24,5325

Corrigé Ex 16 : série $(x; z)$ avec $z = e^y$.

2) b) Calculer le coefficient de corrélation de (x, z) .

Calculons la moyenne de z ($\bar{x} = 4$ est déjà connue) :

$$\bar{z} = \frac{96,0143}{7} \approx 13,7163$$

Calculons la covariance : $\sum x_i z_i \approx 480,1032$, donc $\bar{x}\bar{z} \approx 68,5862$.

$$\text{Cov}(x, z) \approx 68,5862 - 4 \times 13,7163 \approx 68,5862 - 54,8653 \approx 13,7209$$

Calculons la variance de z :

$$\bar{z}^2 \approx 235,3371$$

$$V(z) \approx 235,3371 - 13,7163^2 \approx 47,1995 \text{ et } \sigma(z) \approx 6,8702.$$

Appliquons $r = \frac{\text{Cov}(x, z)}{\sigma(x) \sigma(z)}$ avec $\sigma(x) = 2$:

$$r \approx \frac{13,7209}{2 \times 6,8702} \approx \frac{13,7209}{13,7404} \approx 0,9986$$

$$r \approx 0,9986$$

$\Rightarrow 0,9986 > 0,9663$: le changement de variable a bien redressé le nuage, l'ajustement affine de (x, z) est nettement meilleur

2) c) Donner une équation de la droite de régression de z en x .

Déterminons la pente :

$$a = \frac{\text{Cov}(x, z)}{V(x)} = \frac{13,7209}{4} \approx 3,4302 \approx 3,43$$

Déterminons l'ordonnée à l'origine, avec la pente *non arrondie* :

$$b = \bar{z} - a\bar{x} \approx 13,7163 - 3,4302 \times 4 \approx 13,7163 - 13,7209 \approx -0,0045$$

$$z = 3,43x - 0,005$$

Attention : ici les deux termes de b sont presque égaux. Si on les arrondit avant de soustraire ($13,72 - 13,72$) on trouve 0 au lieu de $-0,005$: il faut impérativement soustraire les valeurs non arrondies.

2) d) En déduire y en fonction de x .

Méthode : on revient de z à y par la fonction réciproque : $z = e^y \iff y = \ln z$, valable car $z > 0$.

Partons de $z = 3,43x - 0,005$ avec $z = e^y$:

$$e^y = 3,43x - 0,005, \text{ et } 3,43x - 0,005 > 0 \text{ dès que } x \geq 1.$$

Composons par $\ln$:

$$y = \ln(3,43x - 0,005)$$

Vérifions le modèle sur une donnée, par exemple $x = 4$: $\ln(13,72 - 0,005) = \ln(13,715) \approx 2,618$, à comparer à la valeur observée 2,62. ✓

3) Selon ce modèle, estimer le profit annuel en 2037.

Déterminons d'abord le rang de 2037 : 2020 a le rang 1, donc le rang vaut année - 2019.

$$2037 - 2019 = 18, \text{ donc } x = 18.$$

Remplaçons x par 18 dans le modèle :

$$y = \ln(3,43 \times 18 - 0,005) = \ln(61,74 - 0,005) = \ln(61,735)$$

$$y \approx 4,1229$$

Le profit estimé en 2037 est d'environ 4,12 millions de dinars.

4) Déterminer à partir de quelle année le profit initial (celui de 2020) sera au moins triplé.

Méthode : la fonction $\ln$ est strictement croissante sur $]0; +\infty[$: l'inéquation $\ln U \geq k$ équivaut à $U \geq e^k$ (le sens de l'inégalité est conservé).

Traduisons l'énoncé : le profit de 2020 vaut 1,26, donc «au moins triplé» s'écrit

$$y \geq 3 \times 1,26, \text{ c'est-à-dire } y \geq 3,78.$$

Réolvons l'inéquation dans le modèle :

$$\ln(3,43x - 0,005) \geq 3,78$$

$$3,43x - 0,005 \geq e^{3,78}$$

$$e^{3,78} \approx 43,8160, \text{ donc } 3,43x \geq 43,8210$$


$$x \geq \frac{43,8210}{3,43} \approx 12,776$$

x étant un entier, la plus petite valeur convenable est $x = 13$.

Vérifions l'encadrement : pour $x = 12$, $y = \ln(41,155) \approx 3,717 < 3,78$; pour $x = 13$, $y = \ln(44,585) \approx 3,797 \geq 3,78$. ✓

Revenons à l'année : $x = 13$ correspond à $2019 + 13 = 2032$.

À partir de 2032 (rang 13), le profit sera au moins triplé.



Corrigé Ex 16 : nuage du profit (croissance concave $\Rightarrow$ modèle $y = \ln(3,43x)$).

Corrigé — Exercice 17

1) Un ajustement affine de (x, y) est-il pertinent? (calculer r .)

Calculons les deux moyennes ($n = 6$) :

$$\bar{x} = \frac{0 + 1 + 2 + 3 + 4 + 5}{6} = \frac{15}{6} = 2,5$$

$$\bar{y} = \frac{80 + 52 + 34 + 22 + 14 + 9}{6} = \frac{211}{6} \approx 35,1667$$

Calculons la covariance avec $\text{Cov}(X, Y) = \overline{xy} - \bar{x}\bar{y}$.

Les produits $x_i y_i$ valent : 0 ; 52 ; 68 ; 66 ; 56 ; 45, de somme 287.

$$\overline{xy} = \frac{287}{6} \approx 47,8333$$

$$\text{Cov}(X, Y) \approx 47,8333 - 2,5 \times 35,1667 \approx 47,8333 - 87,9167 \approx -40,0833$$

Calculons les deux variances avec $V = \overline{u^2} - \bar{u}^2$:

$$\overline{x^2} = \frac{55}{6} \approx 9,1667$$

$$V(X) \approx 9,1667 - 6,25 \approx 2,9167 \text{ et } \sigma(X) \approx 1,7078.$$

$$\overline{y^2} = \frac{11\,021}{6} \approx 1836,8333$$

$$V(Y) \approx 1836,8333 - 1236,6944 \approx 600,1389 \text{ et } \sigma(Y) \approx 24,4977.$$

Appliquons $r = \frac{\text{Cov}(X, Y)}{\sigma(X) \sigma(Y)}$:

$$r \approx \frac{-40,0833}{1,7078 \times 24,4977} \approx \frac{-40,0833}{41,8378} \approx -0,9581$$

$$r \approx -0,96$$

Comparons au seuil usuel : $|r| = 0,96 > \frac{\sqrt{3}}{2} \approx 0,87$ — le critère numérique est donc satisfait.

Regardons pourtant les données de plus près. La droite des moindres carrés serait $y = -13,74x + 69,52$; elle donnerait 69,5 pour $x = 0$ (on observe 80) et 0,8 pour $x = 5$ (on observe 9).

Les écarts successifs $-28, -18, -12, -8, -5$ diminuent en valeur absolue : la décroissance *ralentit*, elle n'est pas constante comme l'exigerait une droite.

De plus, la droite s'annule vers $x \approx 5,06$ puis devient négative, ce qui est impossible pour une mémoire occupée.

⇒ malgré $|r| > 0,87$, l'ajustement affine décrit mal les données : le nuage est nettement incurvé, il faut changer de modèle

2) a) On pose $Z = \ln y$. Dresser le tableau $(x_i ; z_i)$.

Méthode : une décroissance dont l'écart relatif est à peu près constant (ici y est divisé par environ 1,5 à chaque heure) signale un modèle exponentiel : on le linéarise en posant $Z = \ln y$.

Calculons $z_i = \ln y_i$ (arrondis à 10^{-4}) :

x_i	0	1	2	3	4	5
y_i	80	52	34	22	14	9
z_i	4,3820	3,9512	3,5264	3,0910	2,6391	2,1972

Corrigé Ex 17 : série $(x ; z)$ avec $z = \ln y$.

Observons les écarts successifs de z : $-0,431 ; -0,425 ; -0,435 ; -0,452 ; -0,442$. Ils sont quasi constants : la série (x, z) est presque exactement alignée.

2) b) Calculer r .

Calculons la moyenne de z ($\bar{x} = 2,5$ est déjà connue) :

$$\bar{z} = \frac{19,7869}{6} \approx 3,2978$$

Calculons la covariance : $\sum x_i z_i \approx 41,8194$, donc $\overline{xz} \approx 6,9699$.

$$\text{Cov}(x, z) \approx 6,9699 - 2,5 \times 3,2978 \approx 6,9699 - 8,2445 \approx -1,2746$$

Calculons la variance de z :

$$\overline{z^2} \approx 11,4327$$

$$V(z) \approx 11,4327 - 3,2978^2 \approx 0,5571 \text{ et } \sigma(z) \approx 0,7464.$$

Appliquons $r = \frac{\text{Cov}(x, z)}{\sigma(x) \sigma(z)}$ avec $\sigma(x) \approx 1,7078$:

$$r \approx \frac{-1,2746}{1,7078 \times 0,7464} \approx \frac{-1,2746}{1,2747} \approx -0,9999$$

$$r \approx -0,9999$$

$\Rightarrow |r|$ est pratiquement égal à 1 : la série (x, z) est quasi parfaitement alignée, le modèle exponentiel est justifié

2) c) Déterminer la droite de régression de z en x .

Méthode : droite des moindres carrés de z en x : $z = ax + b$ avec $a = \frac{\text{Cov}(x, z)}{V(x)}$, puis $b = \bar{z} - a\bar{x}$.

Déterminons la pente :

$$a = \frac{-1,2746}{2,9167} \approx -0,4370$$

Déterminons l'ordonnée à l'origine, avec la pente non arrondie :

$$b \approx 3,2978 - (-0,43702) \times 2,5 \approx 3,2978 + 1,0926 \approx 4,3904$$

$$z = -0,437x + 4,3904$$

Remarque : ici $b = \bar{z} + 0,437 \times 2,5$ est proche de $z_0 = \ln 80 \approx 4,382$, ce qui est cohérent : b est la valeur du modèle à l'instant initial $x = 0$.

2) d) Établir $y = A e^{Bx}$.

Méthode : on revient de z à y par l'exponentielle : $z = \ln y \iff y = e^z$, puis on sépare avec $e^{u+v} = e^u \times e^v$.

Partons de $z = -0,437x + 4,3904$ avec $z = \ln y$ et $y > 0$:

$$y = e^z = e^{-0,437x+4,3904} = e^{4,3904} \times e^{-0,437x}$$

Calculons $e^{4,3904} \approx 80,67$.

$$y = 80,67 e^{-0,437x} \quad \text{soit} \quad A \approx 80,67 \text{ et } B \approx -0,437$$

Vérifions sur une donnée, par exemple $x = 3$: $80,67 e^{-1,311} \approx 80,67 \times 0,2696 \approx 21,75$, à comparer à la valeur observée 22. ✓

3) Estimer la concentration à $x = 8$ heures.

La grandeur étudiée dans cet exercice est la mémoire y encore occupée par le cache, exprimée en Mo : c'est elle que l'on estime ici.

Remplaçons x par 8 dans le modèle exponentiel :

$$y = 80,67 e^{-0,437 \times 8} = 80,67 e^{-3,496}$$

$$e^{-3,496} \approx 0,03032, \text{ donc } y \approx 80,67 \times 0,03032 \approx 2,446$$

Après 8 heures, le cache occupe encore environ 2,45 Mo.

Remarque : $B < 0$, donc $\lim_{x \rightarrow +\infty} y = 0$ — la mémoire occupée tend vers 0 sans jamais s'annuler. Ce comportement est bien plus réaliste que celui de la droite de la question 1), qui deviendrait négative dès $x > 5,06$.

Corrigé — Exercice 18

1) Par la méthode de Mayer, déterminer une équation de la droite d'ajustement (on partagera la série en deux groupes de 4 points).

Méthode : méthode de Mayer (dite « droite des points moyens ») : on range les points par abscisses croissantes, on les partage en deux groupes de même effectif, on calcule le point moyen G_1 du premier groupe et G_2 du second, et la droite cherchée est la droite (G_1G_2) .

Partageons la série en deux groupes de 4 points : les rangs 1 à 4, puis les rangs 5 à 8.

Calculons le point moyen du premier groupe :

$$x_{G_1} = \frac{1 + 2 + 3 + 4}{4} = \frac{10}{4} = 2,5 \quad \text{et} \quad y_{G_1} = \frac{3 + 5 + 4 + 8}{4} = \frac{20}{4} = 5$$

$$\Rightarrow G_1(2,5; 5)$$

Calculons le point moyen du second groupe :

$$x_{G_2} = \frac{5 + 6 + 7 + 8}{4} = \frac{26}{4} = 6,5 \quad \text{et} \quad y_{G_2} = \frac{9 + 11 + 10 + 14}{4} = \frac{44}{4} = 11$$

$$\Rightarrow G_2(6,5; 11)$$

Déterminons la pente de la droite (G_1G_2) :

$$a = \frac{y_{G_2} - y_{G_1}}{x_{G_2} - x_{G_1}} = \frac{11 - 5}{6,5 - 2,5} = \frac{6}{4} = 1,5$$

Déterminons l'ordonnée à l'origine en écrivant que G_1 appartient à la droite :

$$5 = 1,5 \times 2,5 + b, \text{ donc } b = 5 - 3,75 = 1,25.$$

$$D_M : y = 1,5x + 1,25$$

Vérifions avec G_2 : $1,5 \times 6,5 + 1,25 = 9,75 + 1,25 = 11$. ✓

2) Par la méthode des moindres carrés, déterminer la droite de régression de y en x .

Méthode : droite des moindres carrés de y en x : $y = ax + b$ avec $a = \frac{\text{Cov}(X, Y)}{V(X)}$, puis $b = \bar{y} - a\bar{x}$.

Calculons les deux moyennes ($n = 8$) :

$$\bar{x} = \frac{1 + 2 + \dots + 8}{8} = \frac{36}{8} = 4,5$$

$$\bar{y} = \frac{3 + 5 + 4 + 8 + 9 + 11 + 10 + 14}{8} = \frac{64}{8} = 8$$

Calculons la covariance avec $\text{Cov}(X, Y) = \overline{xy} - \bar{x}\bar{y}$.

Les produits $x_i y_i$ valent : 3; 10; 12; 32; 45; 66; 70; 112, de somme 350.

$$\overline{xy} = \frac{350}{8} = 43,75$$

$$\text{Cov}(X, Y) = 43,75 - 4,5 \times 8 = 43,75 - 36 = 7,75$$

Calculons la variance de X :

$$\overline{x^2} = \frac{204}{8} = 25,5, \text{ donc } V(X) = 25,5 - 4,5^2 = 25,5 - 20,25 = 5,25.$$

Déterminons la pente :

$$a = \frac{7,75}{5,25} = \frac{31}{21} \approx 1,476$$

Déterminons l'ordonnée à l'origine, avec la valeur exacte de a :

$$b = 8 - \frac{31}{21} \times \frac{9}{2} = 8 - \frac{279}{42} = \frac{336 - 279}{42} = \frac{57}{42} = \frac{19}{14} \approx 1,357$$

$$D : y = 1,476x + 1,357$$

3) Comparer les deux droites (pente et ordonnée à l'origine).

Comparons les pentes : 1,5 pour Mayer, 1,476 pour les moindres carrés ; l'écart relatif vaut environ 1,6 %.

Comparons les ordonnées à l'origine : 1,25 pour Mayer, 1,357 pour les moindres carrés.

Comparons les prévisions au milieu du nuage, en $x = 4$: 7,25 contre 7,26 — la différence est négligeable.

⇒ **les deux droites sont pratiquement confondues sur l'intervalle des données**

Elles ne jouent cependant pas le même rôle : Mayer n'utilise que les deux points moyens et se calcule de tête, tandis que les moindres carrés minimisent la somme des carrés des écarts et utilisent *tous* les points.

La droite des moindres carrés est la plus précise ; celle de Mayer n'en est qu'une approximation rapide.

4) Vérifier que les deux droites passent par le point moyen G de la série.

Déterminons le point moyen : $G(\bar{x}; \bar{y})$, soit $G(4,5; 8)$.

Testons la droite de Mayer :

$$1,5 \times 4,5 + 1,25 = 6,75 + 1,25 = 8 = \bar{y}. \quad \checkmark$$

Testons la droite des moindres carrés, avec les coefficients exacts :

$$\frac{31}{21} \times \frac{9}{2} + \frac{19}{14} = \frac{279}{42} + \frac{57}{42} = \frac{336}{42} = 8 = \bar{y}. \quad \checkmark$$

⇒ **les deux droites passent bien par $G(4,5; 8)$**

Justifions le résultat plutôt que de le constater. Pour les moindres carrés, $b = \bar{y} - a\bar{x}$ est précisément la traduction de « G appartient à la droite ».

Pour Mayer, les deux groupes ont le même effectif 4, donc G est le milieu de $[G_1G_2]$: $\frac{2,5 + 6,5}{2} = 4,5$ et $\frac{5 + 11}{2} = 8$. Un milieu appartient toujours au segment, donc $G \in (G_1G_2)$.

5) Avec la droite des moindres carrés, estimer y pour $x = 10$.

Remplaçons x par 10 :

$$y = 1,476 \times 10 + 1,357 = 14,76 + 1,357 = 16,117$$

$$y \approx 16,1$$

Avec les coefficients exacts, $y = \frac{31}{21} \times 10 + \frac{19}{14} = \frac{620}{42} + \frac{57}{42} = \frac{677}{42} \approx 16,119$: l'écart dû aux arrondis est négligeable.

Corrigé — Exercice 19

1) Calculer r pour (x, y) . Un ajustement affine est-il satisfaisant ?

Calculons les deux moyennes ($n = 6$) :

$$\bar{x} = \frac{1 + 2 + 3 + 4 + 5 + 6}{6} = \frac{21}{6} = 3,5$$

$$\bar{y} = \frac{2 + 3,2 + 5,1 + 8,3 + 13 + 21}{6} = \frac{52,6}{6} \approx 8,7667$$

Calculons la covariance avec $\text{Cov}(X, Y) = \overline{xy} - \bar{x}\bar{y}$.

Les produits $x_i y_i$ valent : 2; 6,4; 15,3; 33,2; 65; 126, de somme 247,9.

$$\overline{xy} = \frac{247,9}{6} \approx 41,3167$$

$$\text{Cov}(X, Y) \approx 41,3167 - 3,5 \times 8,7667 \approx 41,3167 - 30,6833 \approx 10,6333$$

Calculons les deux variances avec $V = \overline{u^2} - \bar{u}^2$:

$$\overline{x^2} = \frac{91}{6} \approx 15,1667$$

$$V(X) \approx 15,1667 - 12,25 \approx 2,9167 \text{ et } \sigma(X) \approx 1,7078.$$

$$\overline{y^2} = \frac{719,14}{6} \approx 119,8567$$

$$V(Y) \approx 119,8567 - 76,8544 \approx 43,0022 \text{ et } \sigma(Y) \approx 6,5576.$$

Appliquons $r = \frac{\text{Cov}(X, Y)}{\sigma(X) \sigma(Y)}$:

$$r \approx \frac{10,6333}{1,7078 \times 6,5576} \approx \frac{10,6333}{11,1992} \approx 0,9495$$

$$r \approx 0,95$$

Comparons au seuil usuel : $0,95 > \frac{\sqrt{3}}{2} \approx 0,87$ — le critère numérique est satisfait.

Regardons pourtant les accroissements de y : +1,2; +1,9; +3,2; +4,7; +8. Ils augmentent d'un rang au suivant, alors qu'une droite impose un accroissement constant.

La droite des moindres carrés serait $y = 3,646x - 3,993$: elle donnerait $-0,35$ pour $x = 1$, valeur négative alors qu'on observe 2.

⇒ malgré $r > 0,87$, l'ajustement affine n'est pas satisfaisant : la croissance du nuage est accélérée, pas linéaire

2) a) On pose $Z = \ln y$. Calculer r pour (x, z) .

Méthode : une croissance dont le facteur multiplicatif est à peu près constant (ici y est multiplié par environ 1,6 à chaque rang) signale un modèle exponentiel : on le linéarise en posant $Z = \ln y$.

Calculons $z_i = \ln y_i$ (arrondis à 10^{-4}) :

x_i	1	2	3	4	5	6
y_i	2	3,2	5,1	8,3	13	21
z_i	0,6931	1,1632	1,6292	2,1163	2,5649	3,0445

Corrigé Ex 19 : série $(x; z)$ avec $z = \ln y$.

Observons les écarts successifs de z : 0,470; 0,466; 0,487; 0,449; 0,480. Ils sont quasi constants.

Calculons la moyenne de z ($\bar{x} = 3,5$ est déjà connue) :

$$\bar{z} = \frac{11,2112}{6} \approx 1,8685$$

Calculons la covariance : $\sum x_i z_i \approx 47,4638$, donc $\overline{xz} \approx 7,9106$.

$$\text{Cov}(x, z) \approx 7,9106 - 3,5 \times 1,8685 \approx 7,9106 - 6,5399 \approx 1,3708$$

Calculons la variance de z :

$$\overline{z^2} \approx 4,1357$$

$$V(z) \approx 4,1357 - 1,8685^2 \approx 0,6443 \text{ et } \sigma(z) \approx 0,8027.$$

Appliquons $r = \frac{\text{Cov}(x, z)}{\sigma(x) \sigma(z)}$ avec $\sigma(x) \approx 1,7078$:

$$r \approx \frac{1,3708}{1,7078 \times 0,8027} \approx \frac{1,3708}{1,3708} \approx 1,000$$

$$r \approx 1,000$$

$\Rightarrow$ l'ajustement de (x, z) est quasi parfait : le modèle exponentiel est pleinement justifié

2) b) Déterminer la droite de régression de z en x et en déduire $y = A e^{Bx}$.

Déterminons la pente :

$$a = \frac{\text{Cov}(x, z)}{V(x)} = \frac{1,3708}{2,9167} \approx 0,470$$

Déterminons l'ordonnée à l'origine, avec la pente non arrondie :

$$b = \bar{z} - a \bar{x} \approx 1,8685 - 0,46998 \times 3,5 \approx 1,8685 - 1,6449 \approx 0,224$$

$$z = 0,470x + 0,224$$

Méthode : on revient de z à y par l'exponentielle : $z = \ln y \iff y = e^z$, puis $e^{u+v} = e^u \times e^v$.

Passons à l'exponentielle, avec $y > 0$:

$$y = e^z = e^{0,470x+0,224} = e^{0,224} \times e^{0,470x}$$

Calculons $e^{0,224} \approx 1,251$.

$$y = 1,251 e^{0,470x} \quad \text{soit} \quad A \approx 1,251 \text{ et } B \approx 0,470$$

Vérifions sur une donnée, par exemple $x = 4$: $1,251 e^{1,88} \approx 1,251 \times 6,5535 \approx 8,20$, à comparer à la valeur observée 8,3. ✓

3) Estimer y pour $x = 8$.

Remplaçons x par 8 dans le modèle exponentiel :

$$y = 1,251 e^{0,470 \times 8} = 1,251 e^{3,76}$$

$$e^{3,76} \approx 42,948, \text{ donc } y \approx 1,251 \times 42,948 \approx 53,73$$

$$y \approx 53,7$$

4) Quel modèle retiens-tu ?

Comparons les deux coefficients de corrélation : 0,95 pour l'ajustement affine de (x, y) , contre 1,000 pour l'ajustement affine de (x, z) .

Comparons les modèles sur les données : la droite donne $-0,35$ en $x = 1$ (on observe 2) et 17,9 en $x = 6$ (on observe 21) ; le modèle exponentiel donne 2,00 en $x = 1$ et 20,99 en $x = 6$.

$$\text{On retient le modèle exponentiel } y = 1,251 e^{0,470x}.$$

Il colle aux données sur tout l'intervalle observé et reste strictement positif pour toute valeur de x , ce que la droite ne fait pas.

Corrigé — Exercice 20

1) Calculer le coefficient de corrélation r .

Calculons les deux moyennes ($n = 5$) :

$$\bar{x} = \frac{1 + 2 + 3 + 4 + 5}{5} = \frac{15}{5} = 3$$

$$\bar{y} = \frac{5,2 + 6,9 + 8,1 + 9,8 + 11,1}{5} = \frac{41,1}{5} = 8,22$$

Calculons la covariance avec $\text{Cov}(X, Y) = \overline{xy} - \bar{x}\bar{y}$.

Les produits $x_i y_i$ valent : 5,2 ; 13,8 ; 24,3 ; 39,2 ; 55,5, de somme 138.

$$\overline{xy} = \frac{138}{5} = 27,6$$

$$\text{Cov}(X, Y) = 27,6 - 3 \times 8,22 = 27,6 - 24,66 = 2,94$$

Calculons les deux variances avec $V = \overline{u^2} - \bar{u}^2$:

$$\overline{x^2} = \frac{55}{5} = 11, \text{ donc } V(X) = 11 - 3^2 = 2 \text{ et } \sigma(X) = \sqrt{2} \approx 1,4142.$$

$$\overline{y^2} = \frac{359,51}{5} = 71,902$$

$$V(Y) = 71,902 - 8,22^2 = 71,902 - 67,5684 = 4,3336 \text{ et } \sigma(Y) \approx 2,0817.$$

Appliquons $r = \frac{\text{Cov}(X, Y)}{\sigma(X)\sigma(Y)}$:

$$r \approx \frac{2,94}{1,4142 \times 2,0817} \approx \frac{2,94}{2,9440} \approx 0,9986$$

$$r \approx 0,9986$$

$\Rightarrow 0,9986 > \frac{\sqrt{3}}{2} \approx 0,87$: la corrélation est très forte et positive, l'ajustement affine est pleinement justifié

2) Déterminer les deux droites de régression : y en x , puis x en y .

Méthode : les deux droites ne s'obtiennent pas l'une de l'autre : $D_{y/x} : y = ax + b$ avec $a = \frac{\text{Cov}}{V(X)}$ et $b = \bar{y} - a\bar{x}$;

$D_{x/y} : x = a'y + b'$ avec $a' = \frac{\text{Cov}}{V(Y)}$ et $b' = \bar{x} - a'\bar{y}$. On échange les rôles de X et de Y .

Déterminons d'abord la droite de y en x :

$$a = \frac{\text{Cov}(X, Y)}{V(X)} = \frac{2,94}{2} = 1,47$$

$$b = \bar{y} - a\bar{x} = 8,22 - 1,47 \times 3 = 8,22 - 4,41 = 3,81$$

$$D_{y/x} : y = 1,47x + 3,81$$

Déterminons ensuite la droite de x en y :

$$a' = \frac{\text{Cov}(X, Y)}{V(Y)} = \frac{2,94}{4,3336} \approx 0,6784$$

$$b' = \bar{x} - a'\bar{y} \approx 3 - 0,6784 \times 8,22 \approx 3 - 5,5766 \approx -2,5766$$

$$D_{x/y} : x = 0,6784y - 2,5766$$

3) Vérifier qu'elles se coupent au point moyen G .

Déterminons le point moyen : $G(\bar{x}; \bar{y})$, soit $G(3; 8,22)$.

Testons G dans $D_{y/x}$: $1,47 \times 3 + 3,81 = 4,41 + 3,81 = 8,22 = \bar{y}$. ✓

Testons G dans $D_{x/y}$: $0,6784 \times 8,22 - 2,5766 = 5,5765 - 2,5766 \approx 3 = \bar{x}$. ✓

G appartient donc aux deux droites : elles se coupent bien en G .

Justifions l'unicité du point d'intersection. Écrivons $D_{x/y}$ sous la forme $y = \frac{x + 2,5766}{0,6784} \approx 1,474x + 3,798$: sa pente 1,474 diffère de 1,47, les deux droites ne sont pas confondues.

⇒ **deux droites non confondues ayant un point commun se coupent en ce seul point : l'intersection est exactement $G(3; 8,22)$**

Remarque : ce n'est pas un hasard. Les relations $b = \bar{y} - a\bar{x}$ et $b' = \bar{x} - a'\bar{y}$ signifient précisément que G appartient à chacune des deux droites, quelle que soit la série.

4) Estimer y pour $x = 8$.

On estime y à partir de x : c'est donc la droite de régression de y en x qu'il faut utiliser.

Remplaçons x par 8 dans $D_{y/x}$:

$$y = 1,47 \times 8 + 3,81 = 11,76 + 3,81 = 15,57$$

$$y \approx 15,6$$

Attention : $x = 8$ est hors de l'intervalle observé $[1; 5]$, il s'agit d'une extrapolation ; la valeur n'est valable que si le phénomène reste linéaire au-delà de $x = 5$.

5) Vérifier que le produit des pentes des deux droites de régression est égal à r^2 .

Méthode : le calcul se fait littéralement, à partir des définitions : c'est une identité valable pour toute série double, pas une coïncidence numérique.

Formons le produit des deux pentes :

$$a \times a' = \frac{\text{Cov}(X, Y)}{V(X)} \times \frac{\text{Cov}(X, Y)}{V(Y)} = \frac{(\text{Cov}(X, Y))^2}{V(X) V(Y)}$$

Comparons avec le carré du coefficient de corrélation :

$$r^2 = \left(\frac{\text{Cov}(X, Y)}{\sigma(X)\sigma(Y)} \right)^2 = \frac{(\text{Cov}(X, Y))^2}{\sigma(X)^2 \sigma(Y)^2} = \frac{(\text{Cov}(X, Y))^2}{V(X) V(Y)}$$

Les deux expressions sont identiques.

$$a \times a' = r^2$$

Vérifions numériquement : $a \times a' \approx 1,47 \times 0,67842 \approx 0,9973$ et $r^2 \approx 0,9986^2 \approx 0,9972$. ✓

⇒ $a \times a' = r^2$; en particulier $0 \leq a \times a' \leq 1$, et les deux droites sont confondues si et seulement si $r^2 = 1$

Corrigé — Réponses — QCM & Vrai/Faux

QCM : Q1 → (b) Q2 → (b) Q3 → (c) Q4 → (b).

Q1 : $\text{Cov} < 0 \Rightarrow r < 0$. Q2 : $a = \text{Cov} / V(X)$. Q3 : $0,90 > \sqrt{3}/2 \approx 0,87$. Q4 : les deux droites passent par G .

Vrai / Faux : V1 Vrai V2 Faux V3 Vrai V4 Faux.

V2 : $\text{Cov} > 0 \Rightarrow a = \text{Cov} / V(X) > 0$, la pente est positive. V4 : extrapoler loin donne souvent des valeurs absurdes.